

Buổi 9 — Đặc trưng chuỗi và khả năng dự báo

1. Mục tiêu

Sau buổi này bạn:

- Biến mỗi chuỗi thành **một hàng 20 đặc trưng**, và biết đặc trưng nào đổi theo đơn vị đo, đặc trưng nào không.
- Nói bằng lời **spectral entropy** đo gì, tính tay được trên phổ 4 tần số, và dùng nó xếp hạng 4.000 chuỗi theo độ khó.
- Giải thích bằng ví dụ số vì sao đo độ khó bằng **MASE** của seasonal naive cho kết luận sai, còn **sMAPE** thì không.
- Vẽ **bản đồ** 4.000 chuỗi bằng PCA và tách nhóm chuỗi "dùng baseline, đừng tốn công tune".
- **Phân cụm theo hình dạng** bằng DTW, và chứng minh bằng số vì sao phải chuẩn hoá trước.
- Lập bảng **ABC-XYZ** cho dữ liệu bán lẻ, và chỉ ra vì sao trục XYZ không đo được độ khó dự báo.

2. Nhắc lại buổi trước

Từ buổi 1-3:

- **Naive** dự báo bằng giá trị cuối; **seasonal naive** dự báo bằng giá trị cùng vị trí của vòng trước (tháng 3 năm nay = tháng 3 năm ngoái). **MAE** là trung bình của |sai số|, với sai số = thực tế – dự báo.
- Muốn biết dự báo tốt tới đâu thì **giữ lại đoạn cuối** làm kỳ chấm, chỉ học trên phần trước nó.

Từ buổi 4-8:

- **ACF** r_k : chuỗi giống chính nó dời lùi k bước tới đâu, từ -1 tới 1 .
- **Hệ số biến thiên** (CV) = độ lệch chuẩn / trung bình: dao động to cỡ bao nhiêu phần của mức. Trung bình 100, độ lệch chuẩn 10 $\rightarrow$ CV = 0,1.
- **STL** tách chuỗi thành xu hướng T + mùa vụ S + phần dư R . **Độ mạnh mùa vụ** $F_S = \max(0, 1 - \text{Var}(R)/\text{Var}(S + R))$: gần 1 là mùa vụ lấn át phần dư; **độ mạnh xu hướng** F_T tương tự với T .
- **KPSS**: p nhỏ là có bằng chứng chuỗi không dừng.
- **Pearson** đo quan hệ đường thẳng; **Spearman** là Pearson trên thứ hạng, đo quan hệ "cùng tăng" dù không thẳng.

3. Trạng thái đầu buổi

Sau `python lab.py up` (trong thư mục `lab/`):

Hạng mục	Trạng thái
Dữ liệu	<code>du-lieu/raw/monash-m4-monthly/m4_monthly_dataset.tsf</code> — 48.000 chuỗi theo tháng của cuộc thi M4, dài 60-2.812 tháng, sha256 <code>473aa4fc814b</code>

Hạng mục	Trạng thái
	uci-online-retail-ii/online_retail_II.xlsx (572e362708e6) — 1.067.371 dòng hoá đơn của một cửa hàng bán lẻ trực tuyến, 12/2009 → 12/2011
Nguồn	Monash Time Series Forecasting Repository (Zenodo, CC BY 4.0); UCI Online Retail II (CC BY 4.0)
Môi trường	Python 3.12; numpy 2.5.3, pandas 3.0.5, scipy 1.18.1, statsmodels 0.15.0, scikit-learn 1.9.1, dtaidistance 2.5.1
code/dac_trung.py	đọc dữ liệu, entropy_pho, dac_trung_mot_chuoi, bang_dac_trung, smape, mase, danh_gia_kho_de, tuong_quan_kho_de, de_xuat_chien_luoc, khong_gian_dac_trung, phan_cum_dtw, abc_xyz
code/lab.ipynb	notebook của Lab, bước 1-5
Đang cố tình sai	tuong_quan_kho_de chỉ báo MASE và chỉ Pearson; de_xuat_chien_luoc bảo mọi chuỗi "đáng đầu tư mô hình"; phan_cum_dtw mặc định không chuẩn hoá
Triệu chứng	"entropy không liên quan gì tới độ khó" ($r = -0,05$); kế hoạch tune cả 4.000 chuỗi; các cụm DTW chỉ khác nhau về độ lớn
python lab.py check lúc này	ĐỎ: 4/10 test hỏng

4. Lý thuyết

Dữ liệu chính:

- 4.000 chuỗi lấy ngẫu nhiên (seed 42) trong 48.000 chuỗi M4 theo tháng: doanh số, sản lượng, chỉ số kinh tế... của nhiều ngành.
- Mỗi chuỗi giữ **138 tháng cuối**: 120 tháng để tính đặc trưng, 18 tháng để chấm dự báo.

Từ mới trong buổi

Thuật ngữ	Nghĩa một câu	Ví dụ
đặc trưng (feature) của chuỗi	Một con số tóm một tính chất của cả chuỗi.	CV, r_1 , F_S .
hệ số lệch (skewness)	Đo phân phối lệch về một phía; dương là có vài số rất lớn (đuôi phải dài).	1, 1, 2, 2, 3, 20 → 1,75.
độ nhọn (kurtosis)	Đo giá trị cực đoan hay gặp cỡ nào so với phân phối chuẩn (hình chuông); dương là hay gặp hơn.	Chuỗi có vài tháng tăng vọt.
z-score (chuẩn hoá)	Trừ trung bình rồi chia độ lệch chuẩn: bỏ mức và biên độ, giữ hình dạng.	100, 300, 100, 300 → -1, 1, -1, 1.
tần số	Số vòng lặp mỗi bước; tần số = 1 / chu kỳ.	Lặp mỗi 12 tháng → tần số $1/12 \approx 0,083$.
phổ, periodogram	Bảng cho biết mỗi tần số góp bao nhiêu "năng lượng" (phần dao động) vào chuỗi.	Hộp "Mượn trước" mục 4.2.
spectral entropy	Đo năng lượng trải đều trên các tần số tới đâu, từ 0 (dồn vào một tần số) tới 1 (trải đều).	Sóng đều → gần 0; nhiễu → gần 1.

Thuật ngữ	Nghĩa một câu	Ví dụ
khả năng dự báo (forecastability)	Chuỗi có bao nhiêu cấu trúc lặp lại mà mô hình khai thác được.	Doanh số mùa vụ đều dễ hơn doanh số thất thường.
sMAPE	Trung bình của $200 \times \text{sai số} / (\text{thực tế} + \text{dự báo})$, tính bằng %.	Thực tế 12, dự báo 11 $\rightarrow 200 \times 1 / 23 = 8,7\%$.
MASE	MAE của dự báo chia MAE của seasonal naive trên phần học; dưới 1 là tốt hơn seasonal naive.	MAE 6, MAE seasonal naive 8 $\rightarrow 0,75$.
ngũ phân vị (quintile)	Xếp tăng dần rồi chia 5 nhóm bằng nhau; Q1 là 20% nhỏ nhất.	4.000 chuỗi $\rightarrow$ 5 nhóm 800 chuỗi.
PCA, PC1, PC2	Nén nhiều cột đặc trưng thành 2 cột mới giữ nhiều khác biệt nhất, để vẽ mỗi chuỗi thành một chấm.	15 đặc trưng $\rightarrow$ (PC1, PC2).
DTW (dynamic time warping)	Khoảng cách giữa hai chuỗi cho phép co giãn trục thời gian để khớp đỉnh với đỉnh.	Hai đỉnh lệch một bước: khoảng cách thường (trừ từng cặp cùng thời điểm) 1,41, DTW 0.
cửa sổ Sakoe-Chiba	Giới hạn DTW chỉ được lệch tối đa w bước.	$w = 10$ tháng.
phân cụm phân cấp Ward	Bắt đầu mỗi chuỗi một nhóm, gộp dần hai nhóm gần nhau nhất tới khi còn số nhóm muốn có.	300 chuỗi $\rightarrow$ 4 cụm.
phân loại ABC-XYZ (AX, CZ)	ABC xếp mã hàng theo doanh thu (A lớn nhất), XYZ theo CV (X dao động ít nhất).	Ô AX: bán nhiều và đều.
catch22	Bộ 22 đặc trưng chọn lọc từ 4.791 đặc trưng, dùng chung trong nghiên cứu.	Mục 4.1.
nhu cầu gián đoạn (intermittent demand)	Chuỗi nhiều kỳ bằng 0, thỉnh thoảng mới có số dương.	0, 0, 3, 0, 0, 1.
tune	Thử nhiều cách đặt tham số của một mô hình, giữ cách cho sai số thấp nhất trên dữ liệu kiểm.	Thử 20 cách đặt cho mỗi chuỗi.
FFORMA	Dùng đặc trưng của chuỗi để một mô hình tự chọn trọng số kết hợp nhiều phương pháp dự báo.	Hộp Nâng cao mục 4.4.

4.1 Đặc trưng: mỗi chuỗi thành một hàng số

Vấn đề. 48.000 chuỗi thì không ai xem từng hình. Muốn hỏi "chuỗi nào khó", "chuỗi nào giống nhau", "chuỗi nào hỏng", cần tóm mỗi chuỗi thành vài con số so được với nhau.

Thực giác. Giống hồ sơ sức khỏe: không lưu cả cuốn nhật ký ăn uống, chỉ lưu chiều cao, cân nặng, huyết áp. Mỗi đặc trưng trả lời một câu hỏi về chuỗi. Muốn so công ty bán trăm sản phẩm với công ty bán trăm nghìn, đặc trưng phải **không đổi khi nhân chuỗi với một số**. Chuỗi M4 lại dài ngắn khác nhau, nên mọi chuỗi được cắt về cùng độ dài trước khi tính.


Ví dụ số nhỏ — tự tính tay. Chuỗi $a = (2, 4, 6, 4, 2, 4, 6, 4)$ và chuỗi $1.000 \times a = (2.000, 4.000, \dots)$.

- Trung bình: 4 và 4.000. **Đổi theo đơn vị:** chỉ nói công ty to hay nhỏ.
- CV: độ lệch chuẩn $1,51 / 4 = 0,378$ và $1.512 / 4.000 = 0,378$. **Không đổi.**
- r_1 (buổi 4): 0 ở cả hai, vì nhân mọi độ lệch với 1.000 thì tử số và mẫu số cùng nhân với 1.000^2 .

Hai mươi đặc trưng của buổi, trong `dac_trung_mot_chuoi`:

Nhóm	Đặc trưng	Trả lời câu hỏi
Quy mô (2)	trung bình, độ lệch chuẩn	lớn cỡ nào — đổi theo đơn vị , chỉ để tham chiếu
Phân phối (3)	CV, hệ số lệch, độ nhọn	dao động tương đối to không, có vài tháng cực đoan không
Tự tương quan (4)	r_1 , tổng $r_1^2 + \dots + r_{10}^2$, r_{12} , r_1 của chuỗi sai phân	quá khứ nói gì về tương lai
STL (5)	F_T , F_S , spike, độ dốc và độ cong của xu hướng	cấu trúc xu hướng, mùa vụ; phần dư có cú nhảy lẻ không (spike)
Hình dạng (4)	tỷ lệ số 0, số lần cắt trung bình (cắt ngang đường trung bình), đoạn phẳng, bất ổn định (trung bình 10 đoạn chên nhau cỡ nào)	chuỗi thưa, chuỗi bậc thang, mức trôi dạt
Phổ, tính dừng (2)	spectral entropy, p của KPSS	chuỗi giống nhiều tới đâu, có dừng không

Độc bảng. Chỉ hai đặc trưng quy mô đổi theo đơn vị. Nhóm STL cũng sẽ đổi nếu tính trên chuỗi gốc (xu hướng tính bằng USD thì độ dốc tính bằng USD mỗi tháng). Vì vậy code chạy STL trên chuỗi đã **chuẩn hoá z-score**, như sách FPP của Hyndman (Độc thêm).



Cách đọc hình. Trái: hai chuỗi cùng hình nhưng một chuỗi lớn gấp trăm lần. Phải: sau z-score, hai đường trùng khít — chỉ còn hình dạng.

Đặc trưng còn là máy dò chuỗi hỏng. Trong 4.000 chuỗi mẫu:

- **1 chuỗi hằng:** mọi tháng bằng nhau, KPSS vỡ nên `kpss_p` là NaN.
- **50 chuỗi bậc thang:** "đoạn phẳng" trên một nửa, tức hơn nửa số điểm rơi vào cùng một khoảng giá trị.
- Tỷ lệ số 0 cao là dấu hiệu nhu cầu gián đoạn, cần mô hình riêng (buổi 19).

catch22. Nhóm Lubba lấy 4.791 đặc trưng của thư viện `hctsa`, thử trên 93 bài toán phân loại chuỗi, bỏ đặc trưng kém và đặc trưng trùng nhau, còn 22. Bài học: nhiều đặc trưng không có nghĩa là nhiều thông tin. Một đặc trưng của nó đo **đoạn dài nhất liên tiếp nằm trên trung bình**:

- $A = (1, 5, 6, 7, 5, 1, 1, 2)$, trung bình 3,5: các số trên trung bình là 5, 6, 7, 5 liên nhau → **4**.
- $B = (1, 6, 1, 6, 1, 6, 1, 6)$, trung bình 3,5: trên rồi dưới xen kẽ → **1**.

Hai chuỗi cùng trung bình và gần cùng độ lệch chuẩn (2,5 và 2,7), nhưng A có "quán tính" (đang cao thì còn cao), B đổi chiều mỗi bước. Thư viện `pycatch22` 0.5.0 chỉ phát mã nguồn, cần trình biên dịch C để cài, nên không nằm trong nền buổi này.

Khi nào dùng, khi nào không. Dùng đặc trưng khi có hàng trăm chuỗi trở lên và cần sắp xếp, lọc, nhóm chúng. Không dùng đặc trưng thay cho việc nhìn hình khi chỉ có vài chuỗi; và không so đặc trưng giữa hai chuỗi dài ngắn quá khác nhau khi chưa cắt về cùng độ dài.

Tóm lại. Đặc trưng tóm mỗi chuỗi thành một hàng số để so hàng nghìn chuỗi. Đặc trưng tốt không đổi theo đơn vị và được tính trên cùng độ dài; trung bình và độ lệch chuẩn chỉ để tham chiếu.

Tự kiểm tra. Chuỗi 10, 0, 0, 10, 0, 0, 10, 0, 0. Tỷ lệ số 0 và đoạn dài nhất liên tiếp trên trung bình là bao nhiêu? Nhân chuỗi với 50 thì hai số đó đổi không?


Đáp án (tự làm trước rồi mới đọc)

Tỷ lệ số 0 = $6/9 \approx 0,67$. Trung bình $30/9 \approx 3,3$; chỉ các số 10 nằm trên, không có hai số 10 liền nhau → đoạn dài nhất là **1**. Nhân với 50: cả hai **không đổi** (0×50 vẫn là 0, thứ tự trên/dưới trung bình giữ nguyên). Nhảm hay gặp: nghĩ mọi đặc trưng đều đổi khi đổi đơn vị; chỉ đặc trưng đo **độ lớn** mới đổi.

4.2 Spectral entropy: chuỗi giống nhiễu tới đâu

Vấn đề. Muốn biết trước khi dự báo: chuỗi này có nhịp đều để khai thác, hay gần như ngẫu nhiên? Cần một con số từ 0 tới 1.

Mượn trước — phổ (periodogram) (buổi 12 học kỹ). Mọi chuỗi đều viết được thành tổng của nhiều sóng đều đặn, mỗi sóng một tần số: sóng tần số $1/12$ lặp mỗi 12 tháng, sóng tần số $1/2$ lặp mỗi 2 tháng (tháng lên, tháng xuống). **Phổ** cho biết mỗi sóng góp bao nhiêu phần vào dao động của chuỗi ("năng lượng"). Chuỗi mùa vụ năm đều đặn dồn gần hết năng lượng vào tần số $1/12$; nhiễu thuần thì chia đều cho mọi tần số. Code tính phổ bằng cách Welch (trung bình phổ của nhiều đoạn chồng nhau cho đỡ nhiễu).



Cách đọc hình. Trục ngang là tháng. Sóng trên lặp chậm (mỗi năm một vòng), sóng dưới lặp nhanh nhất mà dữ liệu tháng thể hiện được (tháng lên, tháng xuống): chu kỳ càng ngắn, tần số càng cao.


Trực giác. Chia năng lượng thành các phần $p_1, p_2, \dots$ cộng lại bằng 1, như chia một chiếc bánh. Cả chiếc bánh ở một đĩa thì biết ngay nó ở đâu: dễ đoán. Chia đều cho mọi đĩa thì không đĩa nào nổi bật: khó đoán. Entropy đo "chia đều tới đâu".

Ví dụ số nhỏ — tự tính tay. Phổ có 4 tần số; quy ước $0 \times \ln 0 = 0$; $\ln 4 \approx 1,386$.

Chuỗi	Phần năng lượng p	$-\sum p \ln p$	Chia $\ln 4$
sóng đều	0; 1; 0; 0	$-1 \times \ln 1 = 0$	0
hai nhịp	0,5; 0,5; 0; 0	$-2 \times 0,5 \times \ln 0,5 = 0,693$	0,5
nhiều lý tưởng	0,25; 0,25; 0,25; 0,25	$-4 \times 0,25 \times \ln 0,25 = 1,386$	1

Độc bản. Năng lượng càng dồn vào ít tần số, entropy càng nhỏ. Chia cho $\ln$ (số tần số) để kết quả luôn nằm từ 0 tới 1, bất kể phổ có bao nhiêu tần số.

Năng lượng dồn vào một tần số thì entropy thấp; trải đều mọi tần số thì entropy gần 1



Cách đọc hình.

1. **Trục ngang:** hàng trên là tháng 0 → 119; hàng dưới là tần số, 0 → 0,5 vòng mỗi tháng.
2. **Trục dọc:** hàng trên là giá trị chuỗi; hàng dưới là phần năng lượng của mỗi tần số, từ 0 tới 1.
3. **Ký hiệu:** cột trái là sóng lặp mỗi 12 tháng cộng nhiễu nhỏ; cột phải là nhiễu thuận (seed 0); mỗi cột cam là một tần số.
4. **Nhìn vào đâu:** hàng dưới, cột cao nhất của mỗi ô.
5. **Kết luận:** chuỗi mùa vụ dồn gần hết năng lượng vào tần số lặp mỗi 12 tháng, entropy 0,33; nhiễu thuận chia đều cho mọi tần số, entropy 0,94.

Công thức.

$$H = \frac{-\sum_{i=1}^N p_i \ln p_i}{\ln N}, \quad p_i = \frac{P_i}{\sum_j P_j}$$

- P_i : năng lượng ở tần số thứ i (bỏ tần số 0, vì đó chỉ là mức trung bình). p_i : phần của nó trong tổng. N : số tần số.

Nói bằng lời. Đổi năng lượng thành phần trăm, cộng $-p \ln p$ của từng phần, chia cho $\ln N$. Ở dòng "hai nhịp": $0,693 / 1,386 = 0,5$. FPP: chuỗi có xu hướng và mùa vụ mạnh cho entropy gần 0 (dễ dự báo), chuỗi rất nhiễu cho entropy gần 1 (khó).

NumPy và thư viện. `entropy_pho` trong `code/dac_trung.py`:

```
_, P = signal.welch(y - y.mean(), fs=1.0, nperseg=min(256, y.size))
p = P[1:] / P[1:].sum() # bỏ tần số 0
H = -np.sum(p * np.log(p)) / np.log(p.size)
```

Nixtla `tsfeatures` tính phổ theo cách khác (của Goerg, 2013), nên hai con số không so thẳng được: ghi rõ cách tính khi báo cáo.

Dữ liệu thật. Trên 4.000 chuỗi M4, entropy có trung vị 0,462; một phần năm số chuỗi có entropy từ 0,666 trở lên (mốc dừng ở mục 4.4).

Khi nào dùng, khi nào không. Dùng để xếp hạng nhanh hàng nghìn chuỗi trước khi dự báo, không cần chạy mô hình nào. Không dùng cho chuỗi quá ngắn: ít tần số thì con số chập chờn. Đừng tin nó một mình với chuỗi có xu hướng mạnh: xu hướng dồn năng lượng vào tần số thấp nên entropy thấp, dù phần quanh xu hướng có thể rất nhiều (Bài tập 1).

Tóm lại. Spectral entropy đo năng lượng của chuỗi trải đều trên các tần số tới đâu: gần 0 là có nhịp rõ, gần 1 là giống nhiễu. Nó xếp hạng độ khó mà không cần chạy mô hình.

Tự kiểm tra. Phổ có 2 tần số với phần năng lượng 0,5 và 0,5. Entropy bằng bao nhiêu? Nếu là 0,9 và 0,1 thì lớn hơn hay nhỏ hơn?

Đáp án (tự làm trước rồi mới đọc)

0,5 và 0,5: $-2 \times 0,5 \ln 0,5 / \ln 2 = 0,693 / 0,693 = 1$: chia đều hết mức có thể với 2 tần số. 0,9 và 0,1: $-(0,9 \ln 0,9 + 0,1 \ln 0,1) / \ln 2 = (0,095 + 0,230) / 0,693 \approx 0,47$, nhỏ hơn vì năng lượng dồn vào một phía. Nhầm hay gặp: quên chia $\ln N$, rồi so entropy giữa phổ có số tần số khác nhau.

4.3 Đo độ khó: vì sao đổi MASE sang sMAPE

Vấn đề. Entropy có đoán được **sai số thật** không? Cách kiểm: mỗi chuỗi, dự báo 18 tháng cuối bằng seasonal naive, đo sai số, rồi tính tương quan giữa entropy và sai số trên 4.000 chuỗi. Code đầu buổi đo sai số bằng MASE và kết luận "entropy vô dụng" ($r = -0,05$).

Trực giác. MASE chia sai số cho **sai số của chính seasonal naive trên phần học**. Chuỗi nhiều thì cả tử lẫn mẫu cùng lớn; chuỗi đều thì cả hai cùng nhỏ. Khi mô hình được chấm **là** seasonal naive, tỷ số gần 1 ở mọi chuỗi: phần khó mà entropy đo bị chia mất. sMAPE chia cho **mức của chuỗi**, nên chuỗi nhiều vẫn ra sai số lớn.

Ví dụ số nhỏ — tự tính tay. Hai chuỗi, chu kỳ $m = 4$, học 8 điểm, chấm 2 điểm; dự báo bằng seasonal naive (lặp 4 điểm cuối).

	Phần học	Chấm (thực tế)	Dự báo	sai số
A (đều)	10, 20, 10, 20, 11, 21, 11, 21	12, 22	11, 21	1, 1
B (thất thường)	10, 30, 20, 10, 25, 15, 5, 30	10, 30	25, 15	15, 15

Độc bảng. Tính hai thước đo cho hai chuỗi:

- **Mẫu số của MASE:** trên phần học, mỗi điểm so với điểm cách 4 bước. A: $|11 - 10|, |21 - 20|, |11 - 10|, |21 - 20| \rightarrow$ trung bình 1. B: 15, 15, 15, 20 $\rightarrow$ 16,25.
- **MASE:** $A = 1/1 = 1,00$; $B = 15/16,25 = 0,92$. MASE nói B **đễ hơn** A.
- **sMAPE:** $A = (200 \times 1/23 + 200 \times 1/43) / 2 = (8,7 + 4,7) / 2 = 6,7\%$; $B = (200 \times 15/35 + 200 \times 15/45) / 2 = (85,7 + 66,7) / 2 = 76,2\%$. sMAPE nói B **khó hơn** A hơn mười lần, đúng như mắt thấy.


Công thức.

$$\frac{1}{h} \sum_t y_t - \hat{y}_t$$

- h : số điểm chấm (18); $y_t, \hat{y}_t$: thực tế, dự báo; n : số điểm học (120); m : chu kỳ mùa vụ (12).
- Mẫu số MASE: MAE của seasonal naive trên phần học.

Nói bằng lời. sMAPE: lấy |sai số| chia trung bình của thực tế và dự báo, ra phần trăm, rồi lấy trung bình; ở B, 15 chia $(10 + 25)/2 = 17,5$ ra 85,7%. MASE: MAE kỳ chấm chia MAE của seasonal naive trên phần học; ở B, $15 / 16,25 = 0,92$.

Cùng một dự báo, hai thước đo, hai kết luận: MASE chia cho sai số của CHÍNH seasonal naive



Cách đọc hình.

1. **Trục ngang** (cả hai ô): spectral entropy của chuỗi, $0 \rightarrow 1$.
2. **Trục dọc**: ô trái là sMAPE của seasonal naive (%), cắt ở 60; ô phải là MASE, cắt ở 3 (chấm tròn ở mép trên là chuỗi vượt mức cắt).
3. **Ký hiệu**: mỗi chấm là một chuỗi; đường cam nối trung vị của 5 nhóm ngũ phân vị entropy; vạch đứt ô phải là MASE = 1.
4. **Nhìn vào đâu**: đường cam ở hai ô.
5. **Kết luận**: theo sMAPE, nhóm entropy cao nhất có sai số trung vị gấp đôi các nhóm còn lại; theo MASE, mọi nhóm đều quanh 1.

Tương quan với entropy	Pearson	Spearman
sMAPE	+0,245	+0,216
MASE (chia seasonal naive)	-0,048	+0,027
MASE (chia naive một bước)	-0,381	-0,535

Độc bản. Cùng dữ liệu, cùng dự báo, chỉ đổi mẫu số của thước đo: tương quan đi từ dương, qua 0, tới âm. Dòng cuối chia cho sai số của **naive một bước** (so mỗi tháng với tháng ngay trước). Chuỗi entropy thấp thường trơn, tháng này gần tháng trước, nên mẫu số rất nhỏ và MASE phình to. Chuỗi entropy cao thì tháng nào cũng khác tháng trước, mẫu số lớn, MASE nhỏ, nên kết luận đảo thành "entropy cao là dễ". Hình [hình/ba-thuoc-do.png](#) (ô bước 3) vẽ đúng bảng này.

Khi nào dùng, khi nào không.

- MASE được thiết kế để so **các mô hình trên cùng một chuỗi** (mô hình của bạn có hơn seasonal naive không), không phải để so độ khó giữa các chuỗi.
- sMAPE so được độ khó giữa các chuỗi khác cỡ. Không dùng khi chuỗi có giá trị bằng hoặc gần 0: mẫu số gần 0 làm sMAPE nổ. Nó còn những tật khác (bước 14), nên Phụ lục D khuyên không dùng sMAPE để chấm mô hình. Ở đây mọi chuỗi M4 đều dương, và sMAPE chỉ dùng để xếp hạng độ khó.

Tóm lại. Trước khi nói "đặc trưng X đoán được độ khó", hỏi mẫu số của thước đo là gì. MASE của seasonal naive tự chia mất độ khó, nên luôn quanh 1; SMAPE chia cho mức nên giữ được độ khó. Báo cả Pearson và Spearman.

Tự kiểm tra. Chuỗi C có MAE của seasonal naive trên phần học là 40, trên kỳ chấm là 40, mức quanh 1.000. Chuỗi D: 2 và 2, mức quanh 1.000. MASE và SMAPE (xấp xỉ) của mỗi chuỗi? Chuỗi nào khó hơn?

Đáp án (tự làm trước rồi mới đọc)

MASE: $C = 40/40 = 1$; $D = 2/2 = 1$ — MASE nói hai chuỗi khó như nhau. $SMAPE \approx 200 \times 40 / 2.000 = 4\%$ cho C và $200 \times 2 / 2.000 = 0,2\%$ cho D: C khó hơn nhiều. Nhầm hay gặp: nghĩ MASE = 1 nghĩa là "khó trung bình"; nó chỉ nói kỳ chấm giống phần học, không nói chuỗi khó hay dễ.

4.4 Bản đồ tập dữ liệu và chuỗi nào đáng đầu tư mô hình

Vấn đề. Bỏ hai đặc trưng quy mô, và ba cột có NaN vì chuỗi hằng (hệ số lệch, độ nhọn, p của KPSS), còn 15 đặc trưng: 15 chiều, không vẽ được. Cần nén xuống 2 chiều để thấy cả tập trên một hình: vùng nào dễ, vùng nào khó, chấm nào lạc hẳn.


Trực giác. Nhiều đặc trưng nói cùng một điều theo cách khác nhau. r_1 cao (tháng này giống tháng trước) thì số lần cắt trung bình thấp (chuỗi ít đổi chiều). PCA tìm những **trực chung** như vậy: PC1 là hướng các chuỗi khác nhau nhiều nhất, PC2 là hướng khác nhau nhiều thứ hai, vuông góc với PC1.

Ví dụ số nhỏ — tự tính tay. Ba chuỗi, hai đặc trưng:

Chuỗi	r_1	Số lần cắt trung bình	z của r_1	z của số lần cắt
trơn	0,9	10	1,22	-1,22
vừa	0,5	30	0	0
lổm chởm	0,1	50	-1,22	1,22

Đọc bảng.


- Trước hết chuẩn hoá từng cột (z-score): trừ trung bình của cột, chia độ lệch chuẩn của cột. Không chuẩn hoá thì cột "số lần cắt" (hàng chục) lấn át cột r_1 (dưới 1) chỉ vì đơn vị.
- Sau chuẩn hoá, hai cột luôn ngược dấu nhau: một trực chung đủ tả cả hai. $PC1 = (z \text{ của } r_1 - z \text{ của số lần cắt}) / \sqrt{2}$ cho ba chuỗi 1,73; 0; -1,73 và giữ **toàn bộ** khác biệt; PC2 bằng 0 ở cả ba.



Cách đọc hình. Mỗi chấm là một chuỗi, hai trục là hai đặc trưng đã chuẩn hoá. Các chấm nằm dọc một đường chéo, nên một trục mới (PC1, đường đỏ dài) giữ 98% khác biệt; PC2 vuông góc với nó, giữ 2% còn lại.

Thư viện. `khong_gian_dac_trung`: `StandardScaler` (chuẩn hoá từng cột) rồi `PCA(n_components=2)` của `scikit-learn`; `explained_variance_ratio_` cho phần khác biệt mỗi trục giữ được.

Bản đồ 4.000 chuỗi M4 tháng (18 đặc trưng không phụ thuộc đơn vị → PCA): vùng entropy cao cũng là vùng sMAPE cao (PC1 + PC2 giữ 56% phương sai)



Cách đọc hình.

- Trục ngang** (cả ba ô): PC1, giữ 41% khác biệt; nặng nhất ở số lần cắt trung bình (+) và r_1 , tổng r_k^2 , bất ổn định (–). Phải là chuỗi lờm chờm, trái là chuỗi trơn.
- Trục dọc:** PC2, giữ thêm 15%; nặng nhất ở độ dốc, độ cong xu hướng và F_S .
- Ký hiệu:** mỗi chấm là một chuỗi, cùng vị trí ở ba ô; màu lần lượt là entropy, F_S , sMAPE của seasonal naive (cắt ở 40%).
- Nhìn vào đâu:** phía phải của ba ô; bốn chấm lẻ ở góc trên phải.
- Kết luận:** vùng phải sáng ở ô entropy cũng sáng ở ô sMAPE và tối ở ô F_S : chuỗi lờm chờm, mùa vụ yếu là chuỗi khó; bốn chấm lẻ là chuỗi lạ cần xem tận mắt.

Chiến lược. Ghép hai đặc trưng: entropy $\geq 0,666$ (20% cao nhất) **và** $F_S < 0,4 \rightarrow$ nhóm "dùng baseline". Chỉ dùng entropy thì gạt nhầm cả chuỗi entropy cao mà mùa vụ vẫn mạnh, vẫn có nhịp để mô hình khai thác.

Nhóm	Số chuỗi	sMAPE trung vị của seasonal naive
dùng baseline	137	18,11%
đáng đầu tư mô hình	3.863	6,05%

Đọc bảng. Nhóm 137 chuỗi khó gấp ba. Khó không có nghĩa mô hình phức tạp sẽ cứu được: chúng gần nhiễu, nên mô hình tốt nhất cũng chỉ hơn baseline một chút. Dùng baseline cho nhóm này, dồn thời gian tune cho 3.863 chuỗi còn lại, và báo người dùng rằng dự báo nhóm khó có khoảng bất định rộng.

Khi nào dùng, khi nào không. Dùng bản đồ để chọn mẫu đại diện khi thử mô hình (lấy chuỗi ở mọi vùng), và để tìm chuỗi lạ. Đừng đọc khoảng cách trên bản đồ như khoảng cách thật: PC1 + PC2 chỉ giữ 56%, gần một nửa khác biệt nằm ở các trục khác. Và đừng đưa đặc trưng đổi theo đơn vị vào, nếu không bản đồ chỉ vẽ ra công ty to hay nhỏ.

Nâng cao — có thể bỏ qua lần đọc đầu. **FFORMA** (Montero-Manso và cộng sự, 2020) đi xa hơn: đưa bộ đặc trưng vào một mô hình, để nó học cách trộn nhiều phương pháp dự báo cho từng chuỗi. Cách này đứng thứ hai cuộc thi M4 (buổi 24). Một nghiên cứu năm 2025 (arXiv:2511.08884) thấy foundation model (buổi 34–35) hơn hẳn mô hình nhỏ ở chuỗi dễ dự báo theo phổ, còn ở chuỗi gần nhiễu thì lợi thế đó biến mất.

Tóm lại. Chuẩn hoá từng cột rồi PCA để vẽ cả tập trên hai trục; vùng lờm chờm, mùa vụ yếu là vùng khó. Chuỗi entropy cao và mùa vụ yếu thì dùng baseline.

Tự kiểm tra. Bạn đưa cả "trung bình" (từ 50 tới 500.000) vào PCA mà không chuẩn hoá cột. PC1 sẽ chủ yếu nói điều gì?

Đáp án (tự làm trước rồi mới đọc)

PC1 gần như chỉ là cột trung bình: nó có khác biệt lớn nhất tính theo số, lớn hơn mọi đặc trưng khác hàng nghìn lần. Bản đồ khi đó chỉ xếp chuỗi theo độ lớn. Phải bỏ đặc trưng quy mô và chuẩn hoá từng cột. Nhảm hay gặp: nghĩ PCA tự biết cột nào quan trọng; PCA chỉ thấy con số to hay nhỏ.

4.5 Phân cụm theo hình dạng bằng DTW

Vấn đề. Muốn gom các chuỗi **có cùng hình dạng** (tăng đều, giảm dần, có bước giữa...) để chọn cách dự báo cho từng nhóm. Nhưng hai chuỗi cùng hình dạng có thể lệch nhau một hai bước, và có thể khác nhau hẳn về độ lớn.


Thực giác. So hai chuỗi bằng khoảng cách thường là đặt chúng thẳng hàng theo thời gian, trừ từng cặp. Hai chuỗi có đỉnh lệch nhau một tháng thì bị coi là rất khác. DTW cho phép một điểm của chuỗi này khớp với điểm lân cận của chuỗi kia, như kéo giãn một đoạn dây cao su để đỉnh chạm đỉnh.

Ví dụ số nhỏ — tự tính tay. $x = 0, 0, 1, 0$ và $y = 0, 1, 0, 0$ (đỉnh của y sớm hơn một bước).

- **Khoảng cách thường:** $\sqrt{0^2 + 1^2 + 1^2 + 0^2} = \sqrt{2} \approx 1,41$.
- **DTW:** lập bảng $D(i, j) = (\text{bình phương chênh lệch của } x_i \text{ và } y_j) + \text{nhỏ nhất của ba ô trên, trái, chéo trên-trái}.$

$D(i, j)$	$y_1 = 0$	$y_2 = 1$	$y_3 = 0$	$y_4 = 0$
$x_1 = 0$	0	1	1	1
$x_2 = 0$	0	1	1	1
$x_3 = 1$	1	0	1	2
$x_4 = 0$	1	1	0	0

Đọc bảng. Đường đi rẻ nhất khớp đỉnh x_3 với đỉnh y_2 , rồi chỉ qua các ô 0. Ô cuối bằng 0, nên $DTW = \sqrt{0} = 0$: cùng hình dạng.



Cách đọc hình. Hai chuỗi cùng hình, đỉnh lệch nhau một bước; đường xám nối các cặp điểm được so. Trái: khoảng cách thường so cùng thời điểm, nên đỉnh bị so với đáy. Phải: DTW co giãn trục thời gian để đỉnh khớp đỉnh.

Nhưng với $z = (0, 3, 0, 0)$, cùng hình và đỉnh cao gấp ba, thì $DTW(x, z) = 2$: DTW so **giá trị**, nên phải chuẩn hoá z-score trước. Sau z-score, z thành $(-0,58; 1,73; -0,58; -0,58)$, đúng hình của y , và DTW về lại 0.


$$D(i, j) = (x_i - y_j)^2 + \min \{D(i-1, j), D(i, j-1), D(i-1, j-1)\}, \quad DTW = \sqrt{D(n, n)}$$

- $D(i, j)$: chi phí rẻ nhất để khớp i điểm đầu của x với j điểm đầu của y .

Nói bằng lời. Mỗi ô cộng chênh lệch của cặp điểm đang khớp với chi phí rẻ nhất để đi tới đó; ô cuối là chi phí khớp toàn bộ. Ở ô (3, 2): $(1 - 1)^2 + \min(1, 1, 0) = 0$.

Thư viện. `dtaidistance` tính cả ma trận khoảng cách 300×300 chuỗi trong khoảng 0,3 giây. **Cửa sổ Sakoe-Chiba** bằng 10 chỉ cho khớp lệch tối đa 10 tháng: vừa nhanh hơn, vừa chặn việc khớp tháng 1 với tháng 11. Rồi phân cụm phân cấp Ward gộp dần các chuỗi gần nhau thành 4 cụm (`phan_cum_dtw`).

Phân cụm DTW: chuẩn hoá thì cụm theo HÌNH DẠNG; không chuẩn hoá thì cụm chỉ theo ĐỘ LỚN



Cách đọc hình.

1. **Trục ngang** (mọi ô): tháng 0 → 137.
2. **Trục dọc**: hàng trên là z-score (không đơn vị); hàng dưới là giá trị gốc, mỗi ô một thang.
3. **Ký hiệu**: mỗi cột một cụm, vẽ tối đa 12 chuỗi của cụm; hàng trên phân cụm sau chuẩn hoá, hàng dưới phân cụm trên giá trị gốc.
4. **Nhìn vào đầu**: hình dạng các đường trong từng ô hàng trên; con số trên trục dọc của hàng dưới.
5. **Kết luận**: hàng trên cho bốn hình dạng khác nhau (giảm, tăng đều, bấu giữa, dao động quanh mức); hàng dưới chỉ khác nhau ở độ lớn, thang trục dọc tăng dần từ ô trái sang ô phải.

300 chuỗi, 4 cụm	Cụm 1	Cụm 2	Cụm 3	Cụm 4
Mức trung vị, không chuẩn hoá	1.585	3.310	6.835	9.832
Mức trung vị, chuẩn hoá z-score	2.882	4.891	2.951	4.164

Đọc bảng. Không chuẩn hoá, mức trung vị tăng đều theo số cụm: thuật toán chỉ xếp chuỗi theo độ lớn, việc mà `sort()` làm được. Chuẩn hoá thì mức trung vị lộn xộn: cụm không còn liên quan tới độ lớn.

Khi nào dùng, khi nào không. Dùng DTW khi hình dạng giống nhau nhưng thời điểm lệch nhau đôi chút, như đỉnh Tết âm lịch năm sớm năm muộn. Không dùng khi chính thời điểm là điều bạn quan tâm (đỉnh mùa đông và đỉnh mùa hè phải là khác nhau): khi đó đặt cửa sổ nhỏ hoặc dùng khoảng cách thường. Đừng bỏ chuẩn hoá trừ khi muốn phân cụm theo độ lớn, và nhớ chi phí tăng theo bình phương số chuỗi.

Tóm lại. DTW đo hai chuỗi giống hình dạng tới đâu, cho phép lệch thời gian trong một cửa sổ. Nó so giá trị, nên chuẩn hoá z-score trước; nếu mức trung vị các cụm tăng đều thì bạn đang phân cụm theo độ lớn.

Tự kiểm tra. $x = (1, 3, 1)$ và $y = (1, 1, 3)$. Khoảng cách thường là bao nhiêu? DTW có bằng 0 không?

Đáp án (tự làm trước rồi mới đọc)

Khoảng cách thường: $\sqrt{0 + 4 + 4} \approx 2,83$. DTW: khớp x_1 với y_1 và y_2 , rồi x_2 với y_3 , đều không tốn gì. Nhưng x_3 vẫn phải khớp với y_3 (mọi đường đi đều kết thúc ở ô cuối), chi phí $(1 - 3)^2 = 4$, nên $DTW = \sqrt{4} = 2$, **không bằng 0**. Nhảm hay gặp: nghĩ DTW luôn khớp được mọi độ lệch; đường đi phải đi hết cả hai chuỗi, điểm đầu và điểm cuối bắt buộc khớp nhau.

4.6 Phân loại ABC-XYZ, và vì sao XYZ không đo độ khó

Vấn đề. Doanh nghiệp có hàng nghìn mã hàng và ít người. Cách phổ biến để chia công sức: xếp mã hàng theo hai trục, giá trị (ABC) và dao động (XYZ).


Thực giác. ABC: vài mã hàng mang phần lớn doanh thu, dự báo sai chúng thì đắt. XYZ theo sách giáo khoa: CV nhỏ là "dễ", CV lớn là "khó". Kourentzes (2016) phản bác trực thứ hai. Mã hàng có mùa vụ đều tầm tắp có CV cao nhưng dự báo rất dễ. Mã hàng bán quanh một mức nhưng lên xuống ngẫu nhiên có CV thấp mà khó.

Ví dụ số nhỏ — tự tính tay.

- **ABC** (A = 20% mã đầu, B = 30% tiếp, C = 50% còn lại): 5 mã hàng doanh thu 50, 25, 12, 8, 5. Xếp giảm dần: mã 1 là A ($1/5 = 20\%$ số mã, mang 50% doanh thu), mã 2 là B (tới $2/5 = 40\%$ số mã), ba mã sau là C.
- **XYZ**, ngưỡng quy ước: $CV < 0,5$ là X, $0,5 \leq CV \leq 1$ là Y, $CV > 1$ là Z.


Mã	Bán 4 tháng	Trung bình	Độ lệch chuẩn	CV	Nhóm
P	10, 30, 10, 30	20	11,5	0,58	Y
Q	18, 22, 19, 21	20	1,8	0,09	X

Độc bảng. XYZ xếp Pkhó hơn Q. Nhưng P lặp đúng mỗi 2 tháng: seasonal naive dự báo không sai chút nào. Q lên xuống không theo nhịp nào: tháng sau có thể là 18 hay 22. Sai số dự báo nói ngược với XYZ.



Cách đọc hình. Hai mã hàng cùng trung bình 20. P lặp đúng nhịp 2 tháng nhưng CV cao (nhóm Y); Q lên xuống không theo nhịp nhưng CV thấp (nhóm X). XYZ xếp ngược với độ khó thật.

Phân tầng ABC-XYZ trên Online Retail II: A chiếm phần lớn doanh thu; XYZ chỉ đo biến động, không đo độ khó dự báo



Cách đọc hình.

1. **Trục ngang** (cả hai ô): X, Y, Z (CV tăng dần).
2. **Trục dọc**: A, B, C (doanh thu giảm dần).
3. **Ký hiệu**: ô trái ghi số mã hàng, ô phải ghi phần trăm doanh thu; màu càng đậm số càng lớn.
4. **Nhìn vào đâu**: dòng A ở ô phải; ô AX và CZ ở ô trái.
5. **Kết luận**: dòng A (một phần năm số mã) mang 74,7% doanh thu; ô CZ đông gần gấp bốn ô AX.

Đọc số đo.

- Bảng gồm 2.773 mã hàng có ít nhất 12 tháng doanh thu.
- CV trung vị tăng từ A sang C (0,63; 0,83; 0,92): mã bán ít thì bán thất thường hơn.
- Trên 4.000 chuỗi M4, Spearman giữa CV và sMAPE của seasonal naive là 0,77: ở dữ liệu này, chuỗi dao động mạnh so với mức thường cũng khó. Tương quan cao chưa phải là đo cùng một thứ: như mã P, CV xếp sai đúng những chuỗi có mùa vụ đều, là chuỗi đáng mô hình nhất. (Tương quan của CV với MASE của seasonal naive, -0,11, không nói gì: mục 4.3.)

Khi nào dùng, khi nào không. Dùng ABC để quyết định nơi đặt công sức (ô A đáng mô hình tốt nhất và người xem lại hàng tuần). Không dùng XYZ theo CV để đo độ khó dự báo: Kourentzes đề xuất thay trục XYZ bằng **sai số thật của một dự báo baseline** trên kỳ chấm, như sMAPE ở mục 4.3.

Tóm lại. ABC xếp mã hàng theo doanh thu, cho biết sai ở đâu thì đắt. XYZ theo CV chỉ đo dao động, không đo độ khó: mùa vụ đều có CV cao mà dễ. Đo độ khó bằng sai số thật của baseline.

Tự kiểm tra. Mã R bán 0, 40, 0, 40, 0, 40 (trung bình 20). CV bằng bao nhiêu, xếp X, Y hay Z? Seasonal naive với chu kỳ 2 sai bao nhiêu?

Đáp án (tự làm trước rồi mới đọc)

Độ lệch chuẩn (chia $n - 1 = 5$): mỗi độ lệch là ± 20 , tổng bình phương $6 \times 400 = 2.400$, chia 5 ra 480, căn $\approx 21,9$. CV $\approx 21,9 / 20 \approx 1,1 \rightarrow \mathbf{Z}$, "khó nhất". Seasonal naive chu kỳ 2 dự báo đúng tuyệt đối: sai số **0**. Nhảm hay gặp: coi ô Z là "không dự báo được"; Z chỉ nói doanh số dao động mạnh so với mức.

5. Lab từng bước

Lệnh gõ trong terminal ở thư mục `lab/`. Code các bước nằm sẵn trong `code/lab.ipynb` (mở bằng `python lab.py notebook` hoặc VS Code), chạy từng ô từ trên xuống. Bạn sửa `code/dac_trung.py`; notebook tự nạp lại bản mới.

Bước 1 — Chạy code đầu buổi

Mục đích: thấy ba kết luận sai trước khi sửa.

```
python lab.py up          # một lần: môi trường + dữ liệu M4 và Online Retail II, kiểm sha256
python lab.py check       # 4/10 test đồ
python lab.py notebook    # chạy ô bước 1 (vài chục giây: tính 20 đặc trưng cho 4.000 chuỗi)
```

Đọc kết quả:

- Bảng tương quan chỉ có dòng `mase_snaive` và cột `pearson`: entropy $-0,048$, "không liên quan".
- `{'đáng đầu tư mô hình': 4000}`: không tách chuỗi nào ra.
- Mức trung vị theo 4 cụm DTW tăng đều $1.585 \rightarrow 3.310 \rightarrow 6.835 \rightarrow 9.832$.

Bước 2 — Đặc trưng và entropy trên chuỗi nhỏ

Mục đích: nối ví dụ tay mục 4.1–4.2 với code. Ô bước 2 in 20 đặc trưng của một chuỗi 120 tháng và của chính nó nhân 1.000, và entropy của hai chuỗi trong hình mục 4.2.

Đọc kết quả: chỉ `trung_bình` và `do_lech_chuan` nhân 1.000, mọi đặc trưng khác giữ nguyên; entropy 0,33 và 0,94.

Bước 3 — Entropy so với sai số thật

Mục đích: sửa `tuong_quan_kho_de` theo mục 4.3: báo **ba** thước đo (`smape_snaive`, `mase_snaive`, `mase_naive1_snaive`) và **hai** hệ số (thêm cột `spearman`, dùng `stats.spearmanr`). Chạy lại ô bước 3.

Đọc kết quả: ba dòng entropy như bảng mục 4.3; trung vị MASE ở mọi nhóm ngũ phân vị đều quanh 1. Viết hai câu giải thích vì sao MASE cho ≈ 0 còn MASE chia naive một bước đảo dấu.

Bước 4 — Bản đồ và chiến lược

Mục đích: vẽ bản đồ mục 4.4 và sửa `de_xuat_chien_luoc`: nhấn "dùng baseline" khi `entropy_pho >= nguong_entropy` **và** `do_manh_mua_vu < nguong_mua_vu`, còn lại "đáng đầu tư mô hình". Chạy lại ô bước 4; ô vẽ thêm 3 chuỗi nằm xa tâm bản đồ nhất.

Đọc kết quả: số chuỗi và SMAPE trung vị như bảng mục 4.4. Nói mỗi chuỗi lạ có dấu hiệu gì (đoạn phẳng, KPSS NaN, spike).

Bước 5 — Phân cụm hình dạng và ABC-XYZ

Mục đích: sửa mặc định `chuan_hoa=True` trong `phan_cum_dtw` (mục 4.5), rồi lập bảng ABC-XYZ (mục 4.6). Chạy lại ô bước 5, rồi:

```
python lab.py check      # 10/10 xanh
```

Độc kết quả: mức trung vị theo cụm như dòng dưới của bảng mục 4.5, không còn tăng đều; phép thử "nhân một chuỗi với 100 không đổi cụm" in `True`. Bảng ABC-XYZ như hình mục 4.6. Xanh 10/10 là xong; `test_phan_cum_theo_hinh_dang` còn đỏ thì `chuan_hoa` vẫn là `False`.

6. Lỗi thường gặp & cách chẩn đoán

Triệu chứng	Nguyên nhân	Chẩn đoán	Sửa
"Đặc trưng không liên quan tới độ khó"	đo độ khó bằng MASE của chính baseline	xem mẫu số của thước đo	dùng sMAPE (chuỗi dương) hoặc sai số chia mức
Tương quan đảo dấu khi đổi thước đo	mẫu số khác nhau (naive mùa vụ, naive một bước)	báo nhiều thước đo	nói rõ thước đo trong mọi kết luận
Bản đồ chỉ xếp chuỗi theo độ lớn	đặc trưng quy mô vào PCA, hoặc quên chuẩn hoá cột	xem trọng số của PC1	bỏ đặc trưng quy mô; <code>StandardScaler</code>
Bản đồ chỉ vẽ ra độ dài chuỗi	chuỗi dài ngắn khác nhau	tương quan độ dài × đặc trưng	cắt về cùng độ dài
Bản đồ "đoán" sai số quá giỏi	cột sai số lẫn vào đầu vào PCA	liệt kê cột vào PCA	chỉ đưa cột đặc trưng (<code>cot_ban_do</code>)
Cụm DTW chỉ khác nhau về mức	không chuẩn hoá từng chuỗi	mức trung vị theo cụm có tăng đều không	z-score trước DTW
DTW chạy rất chậm	không giới hạn cửa sổ	đo thời gian	<code>window=</code>
Entropy thấp mà vẫn khó	xu hướng mạnh dồn năng lượng vào tần số thấp	so entropy chuỗi gốc và phần dư STL	tính thêm trên phần dư
<code>kpss</code> báo <code>cannot convert float NaN to integer</code>	chuỗi hằng	<code>np.std(y) == 0</code>	bắt lỗi, đánh dấu chuỗi lạ
XYZ gọi chuỗi mùa vụ đều là "khó"	CV đo dao động, không đo độ khó	so CV với sai số baseline	thay trục XYZ bằng sai số baseline
Entropy không khớp số của thư viện khác	mỗi thư viện một cách tính phổ	in tham số	chốt cách tính, ghi vào báo cáo

7. Bài tập về nhà

- Entropy sau khử xu hướng.** Tính entropy trên chuỗi gốc và trên phần dư STL của 4.000 chuỗi. Tương quan với sMAPE đổi thế nào? Cái nào nên dùng để xếp hạng độ khó?
- Skill score.** Với mỗi chuỗi, tính $\text{skill} = 1 - \text{MAE}(\text{seasonal naive}) / \text{MAE}(\text{naive})$ trên kỳ chấm (dương là seasonal naive hơn naive). Tương quan skill với entropy và với F_S . Kết quả nói gì so với mục 4.3?
- Cụm và chiến lược.** Với 4 cụm DTW, tính sMAPE trung vị của seasonal naive trong từng cụm. Cụm nào nên dùng baseline? So với cách tách bằng entropy + F_S .

8. Tiêu chí "Xong khi"

- [] `python lab.py check` xanh 10/10.
- [] Nộp bản đồ tập dữ liệu và bảng "dùng baseline / đáng đầu tư mô hình" kèm số chuỗi và sMAPE trung vị mỗi nhóm.

- [] Giải thích bằng ví dụ số vì sao entropy tương quan dương với sMAPE nhưng ≈ 0 với MASE của seasonal naive.
- [] Chứng minh phân cụm theo hình dạng: nhân một chuỗi với 100 không đổi cụm.
- [] Chỉ ra ít nhất 2 chuỗi lạ và dấu hiệu nào phát hiện ra chúng.

9. Đọc thêm

- Hyndman, R.J., Athanasopoulos, G. et al. *Forecasting: Principles and Practice, the Pythonic Way* — chương 4 (đặc trưng): <https://otexts.com/fpppy/nbs/04-features.html>
- Lubba, C.H. et al. (2019). catch22: CAnonical Time-series CHaracteristics. *Data Mining and Knowledge Discovery* 33, 1821–1852.
- Goerg, G.M. (2013). Forecastable Component Analysis. *ICML*; arXiv:1205.4591.
- Wang, R. (2025). Time Series Forecastability Measures. arXiv:2507.13556; *Spectral Predictability as a Fast Reliability Indicator* (2025), arXiv:2511.08884.
- Montero-Manso, P., Athanasopoulos, G., Hyndman, R.J. & Talagala, T.S. (2020). FFORMA. *IJF* 36(1), 86–92.
- Kourentzes, N. (2016). ABC-XYZ analysis for forecasting: <https://kourentzes.com/forecasting/2016/10/15/abc-xyz-analysis-for-forecasting/>
- Keogh, E. — *Everything you know about Dynamic Time Warping is Wrong*: https://www.cs.ucr.edu/~eamonn/DTW_myths.pdf
- Thư viện: `dtaidistance`, Nixtla `tsfeatures` (42 đặc trưng, không cập nhật từ 2023), `tsfresh` (782 đặc trưng), `pycatch22`.
- Godahewa, R. et al. (2021). Monash Time Series Forecasting Archive. *NeurIPS Datasets and Benchmarks*.