

Buổi 11 — Ngoại lai và điểm gãy

1. Mục tiêu

Sau buổi này bạn:

- Phân biệt **bốn loại bất thường**: điểm đơn, dịch mức, thay đổi tạm, đổi phương sai; mỗi loại cần một cách phát hiện và một cách xử lý.
- Chỉ ra bằng 10 số tính tay vì sao ngưỡng **3σ** tự mù trước ngoại lai (**masking**), và vì sao **MAD** thì không.
- Dùng **bộ lọc Hampel** (MAD trên cửa sổ trượt) cho chuỗi có xu hướng.
- Chấp nhận một điều khó chịu: không ngưỡng thống kê nào phân biệt được "lỗi đo" với "sự kiện thật" như Tết; cần **nhật ký sự kiện**.
- Tìm **điểm gãy** bằng PELT, hiểu **penalty** bằng ví dụ tính tay, và tự quét penalty để chọn kết quả ổn định.
- So ba cách xử lý giai đoạn COVID trên dữ liệu thật, và nói được cách nào hợp cho mục đích nào.

2. Nhắc lại buổi trước

Từ buổi 2–6:

- **Độ lệch chuẩn** s (hay σ): khoảng cách điển hình tới trung bình. **Trung vị**: số đứng giữa khi xếp tăng dần; vài số cực lớn không kéo được nó.
- **STL robust** (buổi 6): tách xu hướng + mùa vụ + phần dư, và giảm trọng số điểm có phần dư lớn; điểm lạ nằm lại trong phần dư.
- **Log** (buổi 5): biến "tăng gấp mấy lần" thành "cộng thêm bao nhiêu", nên dao động tỷ lệ với mức thành dao động đều.

Từ buổi 10:

- **Cột cờ**: mọi lần sửa dữ liệu phải để lại dấu vết (`da_dien`, `ngghi_ngo`). Hôm nay thêm `da_sua`.
- **Giữ đủ mốc**: xóa dòng làm thủng lưới thời gian; thiếu mốc là loại thiếu khó thấy nhất.
- **MAE**: trung bình |thực tế – dự báo|; sai số = thực tế – dự báo, dương là dự báo thấp hơn thực tế.

3. Trạng thái đầu buổi

Sau `python lab.py up` (trong thư mục `lab/`):

Hạng mục	Trạng thái
Dữ liệu 1	<code>du-lieu/raw/wikipedia-vi-tong/</code> — 3.653 ngày tổng lượt xem Wikipedia tiếng Việt, 2016–2025, sha256 <code>481d604d1b58</code>
Dữ liệu 2	<code>wikipedia-vi-tet/</code> — 3.653 ngày lượt xem bài "Tết Nguyên Đán", sha256 <code>8f9e15ea3055</code>
Dữ liệu 3	<code>eurostat-hanh-khach-hang-khong/</code> — 218 tháng hành khách hàng không 27 nước EU, 1/2008 → 2/2026, sha256 <code>6ce5178cf876</code>
Nguồn	Wikimedia Pageviews (CC0 1.0); Eurostat <code>avia_paoc</code> (CC BY 4.0)

Hạng mục	Trạng thái
Môi trường	Python 3.12; numpy 2.5.3, pandas 3.0.5, scipy 1.18.1, statsmodels 0.15.0, ruptures 1.1.10
code/ bat_thuong.py	đọc dữ liệu, <code>z_score</code> , <code>iqr</code> , <code>mad_score</code> , <code>hampel</code> , <code>stl_robust</code> , <code>so_sanh_bat</code> , <code>masking</code> , <code>sinh_chuoi_co_loi</code> , <code>dan_nhan</code> , <code>doi_phuong_sai</code> , <code>diem_gay</code> , <code>quet_penalty</code> , <code>ba_cach_xu_ly_covid</code> , <code>xu_ly_ngoai_lai</code>
code/lab.ipynb	notebook của Lab, bước 1-5
Đang cố tình sai	<code>xu_ly_ngoai_lai</code> xoá mọi điểm vượt 3σ và không biết nhật ký sự kiện; <code>diem_gay</code> chạy PELT trên mức gốc, không lấy log; <code>doi_phuong_sai</code> đo trên chuỗi gốc bằng độ lệch chuẩn
Triệu chứng	chuỗi Tết mất cả 10 đỉnh và thung mốc; hàng không EU ra 43 điểm gãy không ai giải thích được; không thấy đoạn "đối phương sai" cài sẵn trong chuỗi mô phỏng
python lab.py check lúc này	ĐỎ: 4/12 test hỏng

4. Lý thuyết

Từ mới trong buổi

Thuật ngữ	Nghĩa một câu	Ví dụ
ngoại lai (outlier)	Giá trị lệch hẳn khỏi phần còn lại, do lỗi đo hay do sự kiện thật.	10, 12, 11, 50 , 12.
AO (điểm đơn)	Một điểm lệch, trước và sau vẫn như cũ.	Gõ nhầm thêm một số 0.
dịch mức (LS, level shift)	Mức trung bình đột ngột rồi giữ luôn ở mức mới.	Từ tháng 3 mở thêm quầy, bán quanh 130 thay vì 100.
thay đổi tạm (TC)	Mức nhảy rồi hồi dần về như cũ.	Khuyến mãi một tuần.
đối phương sai	Mức giữ nguyên, độ dao động đổi.	Thay cảm biến kém chính xác hơn.
z-score	Khoảng cách tới trung bình tính bằng số lần độ lệch chuẩn.	Trung bình 10, $s = 2$, giá trị 16 $\rightarrow z = 3$.
MAD	Trung vị của khoảng cách tới trung vị , nhân 1,4826 để cùng thang với độ lệch chuẩn.	Mục 4.3.
masking / swamping	Masking: ngoại lai che chính nó và các ngoại lai khác. Swamping: ngoại lai làm điểm bình thường bị gắn cờ oan.	Mục 4.2.
bộ lọc Hampel	MAD tính trên cửa sổ trượt quanh mỗi điểm, so với trung vị địa phương.	Cửa sổ ± 15 ngày.
winsorize	Kéo giá trị bị gắn cờ về một mức hợp lý (ở đây: trung vị địa phương), không xoá.	50 $\rightarrow$ 12.
nhật ký sự kiện	Danh sách mốc đã biết có sự kiện thật, không được sửa như lỗi.	Các ngày Tết, đợt COVID.
biến giả (dummy)	Cột 0/1 báo mốc nào nằm trong một sự kiện, để mô hình học riêng ảnh hưởng của nó.	<code>covid</code> = 1 từ 3/2020 tới 6/2021.
điểm gãy (change point)	Mốc mà tính chất của chuỗi (mức, độ dao động) đổi.	Tháng 2/2020 với hàng không.

Thuật ngữ	Nghĩa một câu	Ví dụ
hàm chi phí	Con số đo một đoạn chuỗi "không đều" tới đâu; ở đây là tổng bình phương khoảng cách tới trung bình đoạn.	Mục 4.5.
PELT	Thuật toán tìm bộ điểm gây làm tổng chi phí + phạt nhỏ nhất, nhanh nhờ loại bớt phương án.	<code>ruptures.Pelt</code> .
penalty (phạt)	Chi phí cộng thêm cho mỗi điểm gây; phạt lớn thì ít điểm gây.	$3 \ln n$.
nhân quả / không nhân quả	Nhân quả: kết quả tại t chỉ dùng dữ liệu tới t . Không nhân quả: nhìn cả dữ liệu sau t .	Trung vị cửa sổ ± 15 ngày là không nhân quả.
CUSUM, CROPS	CUSUM: cộng dồn độ lệch để báo động sớm. CROPS: thuật toán quét cả dải penalty.	Hộp Nâng cao mục 4.5.
MAPE	Trung bình của $ \text{sai số} / \text{thực tế} $, tính bằng %.	Thực tế 100, dự báo 90 $\rightarrow$ 10%.


4.1 Bốn loại bất thường

Vấn đề. "Ngoại lai" không phải một thứ. Một điểm lệch, một bậc thang, một cú nhảy rồi hồi, một đoạn dao động mạnh lên: mỗi thứ cần cách phát hiện khác và cách xử lý khác (Chen & Liu, 1993).


Ví dụ số nhỏ — tự tính tay. Bốn chuỗi 8 điểm, mức nền 10:

Loại	Chuỗi	Dấu hiệu
AO (điểm đơn)	10, 10, 10, 25 , 10, 10, 10, 10	một điểm lệch, rồi như cũ
dịch mức	10, 10, 10, 20 , 20, 20, 20, 20	lệch và ở lại
thay đổi tạm	10, 10, 10, 20 , 15, 12, 11, 10	lệch rồi hồi dần
đổi phương sai	10, 10, 10, 14 , 6, 13, 7, 14	mức vẫn quanh 10, dao động to hơn

Đọc bảng. Nhìn điểm thứ tư thì ba dòng đầu giống nhau; chỉ **những điểm sau** cho biết loại. Vì vậy một ngưỡng nhìn từng điểm riêng lẻ chỉ bắt được AO; muốn thấy dịch mức và thay đổi tạm phải tìm điểm gây (mục 4.5); muốn thấy đổi phương sai phải nhìn độ dao động của phần dư.



Cách đọc hình. Bốn chuỗi 8 điểm, mức nền 10; điểm thứ tư (đỏ) lệch ở cả bốn. Chỉ các điểm sau nó cho biết loại: quay về ngay, ở lại, hồi dần, hay giữ mức mà dao động to hơn.



Cách đọc hình.

1. **Trục ngang:** ngày, 1/2023 → 2/2024 (chuỗi mô phỏng 400 ngày, seed 0).
2. **Trục dọc:** giá trị của chuỗi.
3. **Ký hiệu:** xám là chuỗi; sao đen là vị trí bất thường cài sẵn; mỗi vạch màu là một nhãn thuật toán gán, màu theo loại (chú giải).
4. **Nhìn vào đầu:** mỗi sao đen có vạch cùng chỗ không, vạch đó màu gì.
5. **Kết luận:** cả 6 bất thường cài sẵn được gán đúng loại, kèm 3 cảnh báo giả; dịch mức tháng 7 được thấy nhờ tìm điểm gãy, không nhờ ngưỡng từng điểm.

Tóm lại. Bốn loại: điểm đơn, dịch mức, thay đổi tạm, đối phương sai. Loại quyết định cách phát hiện và cách xử lý, không phải độ lớn.

Tự kiểm tra. Doanh số: 50, 52, 49, 90, 88, 91, 89, 90. Loại gì? Ngưỡng nhìn từng điểm có đủ không?

Đáp án (tự làm trước rồi mới đọc)

Dịch mức: từ điểm thứ tư mức lên quanh 90 và ở lại. Ngưỡng từng điểm thấy điểm 90 đầu tiên lạ, nhưng sau đó mức địa phương đã thành 90, nên các điểm sau trông bình thường; nó không nói được "mức đã đổi hẳn". Cần tìm điểm gãy. Nhầm hay gặp: sửa điểm 90 đầu tiên như lỗi đo.

4.2 z-score và masking: ngưỡng tự mù


Vấn đề. Cách quen thuộc nhất: tính $z = (y - \bar{y})/s$, gán cờ khi $|z| > 3$. Nhưng chính ngoại lai kéo $\bar{y}$ và s lên.

Ví dụ số nhỏ — tự tính tay. Mười số (10, 12, 11, 13, 12, 50, 11, 12, 13, 12) :

- Trung bình $156 / 10 = 15,6$; độ lệch chuẩn $s \approx 12,1$ (số 50 làm nó phình ra; bỏ số 50 thì chỉ khoảng 1).
- z của 50 = $(50 - 15,6) / 12,1 \approx 2,84$: **không** vượt 3, không bị gán cờ.
- Thay số 12 cuối bằng 60: $s \approx 18,4$, z của 50 còn 1,61, của 60 chỉ 2,15. Hai ngoại lai che nhau, không cái nào bị bắt.

Tệ hơn: với 10 số, $|z|$ không bao giờ vượt được $(n - 1)/\sqrt{n} = 9/\sqrt{10} \approx 2,85$, dù ngoại lai lớn tới đâu. Ngưỡng 3 ở đây không bao giờ gán cờ gì.

Masking trên 10 số: ngoại lai kéo ngưỡng 3 σ lên cao hơn chính nó; ngưỡng MAD đúng yên sát dữ liệu



Cách đọc hình.

1. **Trục ngang:** vị trí 1 $\rightarrow$ 10.
2. **Trục dọc:** giá trị.
3. **Ký hiệu:** ô trái là dãy của ví dụ, ô phải là dãy có thêm ngoại lai thứ hai; chấm xanh là các số; vạch cam đứt là trung bình + 3 σ ; vạch xanh lá chấm là trung vị + 3·MAD (mục 4.3).
4. **Nhìn vào đầu:** vị trí vạch cam so với các chấm lẻ ở hai ô.
5. **Kết luận:** một ngoại lai đẩy ngưỡng 3 σ lên 52, cao hơn chính nó; thêm ngoại lai thứ hai, ngưỡng lên gần 76; ngưỡng MAD đúng yên sát dữ liệu và bắt được cả hai.

Trên dữ liệu thật. Trên 3.653 ngày lượt xem Wikipedia tiếng Việt, 3 σ gần cỡ 16 ngày. Thêm **một** ngày giả thật lớn, số ngày bị gần cỡ tụt còn **5**: mười một ngày "bất thường" biến mất chỉ vì thước đo đối (hình [hình/masking.png](#), ô bước 1). Chiều ngược lại gọi là **swamping**: ngoại lai làm điểm bình thường bị gần cỡ oan.

Khi nào dùng, khi nào không. Dùng z-score khi dữ liệu gần hình chuông, không có xu hướng, và ngoại lai rất ít so với số điểm. Không dùng khi mẫu nhỏ, khi có nhiều ngoại lai, hay khi chuỗi có xu hướng (mục 4.3).

Tóm lại. z-score dùng trung bình và độ lệch chuẩn, mà cả hai đều bị ngoại lai kéo: ngoại lai tự che mình và che nhau. Với mẫu nhỏ, ngưỡng 3 có thể không bao giờ vượt được.

Tự kiểm tra. Năm số (5, 5, 5, 5, 100). Tính z của 100. Có bị gần cỡ ở ngưỡng 3 không?


Đáp án (tự làm trước rồi mới đọc)

Trung bình 24; độ lệch (−19, −19, −19, −19, 76); tổng bình phương $4 \times 361 + 5.776 = 7.220$; chia $n - 1$ ra 1.805, căn $\approx 42,5$. Vậy $z = 76/42,5 \approx 1,79$: **không** bị gần cỡ, dù 100 lớn hơn hẳn các số kia. Với năm số, $|z|$ tối đa chỉ là $4/\sqrt{5} \approx 1,79$. Nhầm hay gặp: tin "không vượt 3 σ " nghĩa là "không có ngoại lai".

4.3 MAD và bộ lọc Hampel

Vấn đề. Cần một thước đo mức và độ dao động mà vài điểm cực lớn không kéo được. Và cần so mỗi điểm với **mức quanh nó**, vì chuỗi có xu hướng thì "trung bình cả chuỗi" không có ý nghĩa.

Trực giác. Trung vị không quan tâm số lớn nhất lớn cỡ nào, chỉ quan tâm nó nằm ở nửa trên. Lấy trung vị cho cả mức lẫn độ dao động thì một nửa dữ liệu phải hỏng mới kéo lệch được.



Cách đọc hình. Trục ngang là giá trị của số lạ trong dãy 10 số (chín số còn lại quanh 12), trục dọc là độ dao động đo được. Độ lệch chuẩn tăng thẳng theo số lạ; MAD đứng yên ở 1,48.

Ví dụ số nhỏ — tự tính tay. Cùng 10 số:

- Trung vị: xếp tăng dần, hai số giữa là 12 và 12 → **12**.
- Khoảng cách tới 12: (2, 0, 1, 1, 0, 38, 1, 0, 1, 0); xếp tăng (0, 0, 0, 0, 1, 1, 1, 1, 2, 38); trung vị **1**.
- $MAD = 1,4826 \times 1 \approx 1,48$. Điểm của 50: $38 / 1,48 \approx \mathbf{25,6}$, vượt xa 3: bị gắn cờ. Điểm của 10: $2 / 1,48 \approx 1,35$: bình thường.

$$\text{điểm}_t = \frac{|y_t - \text{median}(y)|}{1,4826 \cdot \text{median}|y - \text{median}(y)|}$$


- Tử số: điểm cách trung vị bao xa. Mẫu số: MAD, độ dao động điển hình tính bằng trung vị. 1,4826 đưa MAD về cùng thang với độ lệch chuẩn khi dữ liệu hình chuông.

Nói bằng lời. Chia khoảng cách tới trung vị cho độ dao động điển hình; lớn hơn 3 là ngoại lai. Ở ví dụ: $38/1,48 \approx 25,6$.

Hampel là đúng công thức đó trên **cửa sổ trượt** $\pm k$ điểm quanh mỗi điểm (`hampel` trong code):


```
trung_vi = y.rolling(2 * k + 1, center=True, min_periods=k).median()
mad = (y - trung_vi).abs().rolling(2 * k + 1, center=True, min_periods=k).median()
co = (y - trung_vi).abs() / (1.4826 * mad) > 3
```

Cửa sổ phải dài hơn các dao động bình thường và ngắn hơn các thay đổi cấu trúc. `center=True` nhìn cả hai phía. Vì vậy Hampel **không nhân quả** (buổi 12): dùng được để làm sạch lịch sử, không dùng được làm đặc trưng đầu vào cho dự báo.



Cách đọc hình. Trục ngang là thời gian, trục dọc là giá trị; dải xanh là trung vị $\pm 3 \cdot MAD$ của cửa sổ ± 15 điểm, đi theo xu hướng. Điểm vọt khỏi dải bị gắn cờ (đỏ); ngưỡng 3σ toàn chuỗi (nét đứt) nằm cao hơn mọi điểm nên không bắt được gì.

Ngưỡng TOÀN CHUỖI mùa trước chuỗi có xu hướng: mức tham chiếu phải là mức ĐỊA PHƯƠNG



Cách đọc hình.

1. **Trục ngang** (cả hai ô): năm, 2016 → 2026.
2. **Trục dọc**: lượt xem mỗi ngày (triệu).
3. **Ký hiệu**: xám là chuỗi; chấm cam (trên) là ngày 3σ gắn cờ; chấm xanh (dưới) là ngày Hampel ± 15 ngày gắn cờ.
4. **Nhìn vào đầu**: chấm cam dồn ở đầu; chấm xanh rải ra sao.
5. **Kết luận**: 3σ chỉ gắn cờ những ngày mức cao, tức nó đang nói "những ngày này đông"; Hampel gắn cờ rải đều mười năm, vì so với mức địa phương.

Cách (lượt xem Wikipedia, 3.653 ngày)	Số ngày gắn cờ	Tỷ lệ
3σ toàn chuỗi	16	0,44%
IQR 1,5 (ngoài khoảng quantile 0,25 → 0,75, nói mỗi phía 1,5 lần độ rộng khoảng đó)	27	0,74%
MAD 3, toàn chuỗi	15	0,41%
Hampel ± 15 ngày	121	3,31%
STL robust, mùa vụ tuần	616	16,86%

Đọc bảng. Ba cách toàn chuỗi gắn cờ quá ít; STL robust gắn cờ một phần sáu số ngày, quá nhiều, vì phần dư của nó còn cả mùa vụ năm mà mùa vụ tuần không giải thích được. Trước khi tin một ngưỡng, xem nó gắn cờ bao nhiêu phần trăm dữ liệu.

Khi nào dùng, khi nào không. Dùng MAD thay độ lệch chuẩn gần như mọi lúc tìm ngoại lai; dùng Hampel khi chuỗi có xu hướng hay mức đổi dần. Không dùng Hampel khi ngoại lai chiếm gần nửa cửa sổ (trung vị cũng hỏng), và không dùng bản `center=True` cho đặc trưng đầu vào của dự báo.

Tóm lại. MAD đo độ dao động bằng trung vị nên ngoại lai không kéo được. Hampel so mỗi điểm với trung vị và MAD của cửa sổ quanh nó, nên xu hướng không làm nó mù.

Tự kiểm tra. Tính điểm MAD của 100 trong (5, 5, 5, 6, 100).

Đáp án (tự làm trước rồi mới đọc)


Trung vị 5. Khoảng cách (0, 0, 0, 1, 95), trung vị 0 → MAD = 0: không chia được. Khi hơn nửa số điểm bằng nhau, MAD bằng 0; trong code, `hampel` bỏ qua cửa sổ có MAD bằng 0, còn `mad_score` trả điểm 0.

Chuỗi bậc thang (buổi 9) hay gặp chuyện này. Nhầm hay gặp: chia cho 0 rồi gán cờ mọi điểm khác trung vị.

4.4 Tết không phải ngoại lai: nhật ký sự kiện và cách xử lý

Vấn đề. Ngưỡng thống kê chỉ nói "điểm này khác". Nó không biết "khác" là lỗi đo hay là điều ta đang muốn dự báo.

Sự kiện **THẬT**, không phải **lỗi**: xoá đi là xoá mất thứ đáng dự báo nhất — và STL không cứu được vì Tết theo lịch âm




Cách đọc hình.

1. **Trục ngang:** ô trái là năm 2016 → 2026; ô phải là năm.
2. **Trục dọc:** ô trái là lượt xem bài "Tết Nguyên Đán" mỗi ngày (nghìn); ô phải là ngày thứ mấy trong năm dương lịch của đỉnh Tết.
3. **Ký hiệu:** ô trái, vòng đen là đỉnh Tết thật, chấm cam là ngày 3σ gán cờ; ô phải, mỗi chấm xanh là đỉnh Tết của một năm.
4. **Nhìn vào đâu:** vòng đen có chấm cam không; độ cao các chấm xanh ở ô phải.
5. **Kết luận:** cả 10 đỉnh Tết bị gán cờ "ngoại lai"; ngày dương lịch của đỉnh xê dịch tới 25 ngày giữa các năm.

Cả năm cách ở mục 4.3, kể cả Hampel và STL robust, đều gán cờ 10/10 đỉnh. Về thống kê, một đỉnh gặp 10 lần nên **đúng là** bất thường. STL cũng không học được đỉnh này làm mùa vụ, vì Tết theo lịch âm, ngày dương xê dịch. Cách sửa đúng là **nhật ký sự kiện**: danh sách mốc đã biết, không được sửa (buổi 13 biến nó thành biến giả lịch âm).

Ví dụ số nhỏ — tự tính tay. Chuỗi (12, 11, 13, 90, 12), trung vị địa phương 12, điểm 90 bị gán cờ:

- **Xoá:** (12, 11, 13, —, 12) : mất một mốc, lưới thời gian thủng.
- **Winsorize:** (12, 11, 13, 12, 12) : giữ mốc, giá trị kéo về trung vị địa phương, cột `da_sua` = 1.
- Nếu ngày đó có trong nhật ký sự kiện (Tết): **giữ nguyên 90**.



Cách đọc hình. Trục ngang là mốc, trục dọc là giá trị; dấu x xám là số bị gán cờ. Xoá để lại một lỗ; winsorize thay nó bằng trung vị địa phương 12 và giữ đủ mốc.

Năm cách xử lý sau khi phát hiện, từ nhẹ tới nặng:

Cách	Làm gì	Hợp với	Rủi ro
giữ + gán cờ	không sửa, thêm cột cờ	sự kiện thật; khi chưa chắc	mô hình nhảy với ngoại lai bị kéo lệch
winsorize	kéo về trung vị địa phương	điểm đơn do lỗi đo	mất biên độ thật nếu gán nhầm
coi là thiếu	đặt NaN, xử lý như buổi 10	đoạn dữ liệu hỏng dài	tạo lỗ, phải chọn cách điền
biến giả	thêm cột 0/1	dịch mức, thay đổi tạm, sự kiện lặp lại	phải biết mốc; nhiều biến giả dễ học thuộc
cắt dữ liệu cũ	chỉ dùng phần sau điểm gãy	cấu trúc đổi hẳn	mất mẫu (mục 4.6)

Độc bảng. Cột "Hợp với" đi theo **loại** bất thường: một điểm đơn rất lớn vẫn chỉ cần winsorize; một dịch mức nhỏ vẫn cần biến giả, vì nó ảnh hưởng mọi dự báo về sau. Và luôn giữ đủ số mốc.

Tóm lại. Ngưỡng không phân biệt được lỗi đo với sự kiện thật; nhật ký sự kiện thì làm được. Sửa bằng winsorize hay biến giả, không xoá mốc.

Tự kiểm tra. Một cửa hàng có ngày doanh số gấp 8 lần bình thường vì Black Friday, lặp mỗi năm. Hampel gán cờ ngày đó. Xử lý thế nào?

Đáp án (tự làm trước rồi mới đọc)

Đưa Black Friday vào nhật ký sự kiện và **giữ nguyên**; khi dự báo, thêm biến giả cho ngày đó (sự kiện lặp lại, biết trước). Winsorize sẽ xoá chính cái đỉnh mà cửa hàng cần dự báo để chuẩn bị hàng. Nhầm hay gặp: tin nhãn "ngoại lai" của thuật toán.

4.5 Điểm gãy: PELT và penalty

Vấn đề. Dịch mức và thay đổi tạm không lộ ra ở một điểm, mà ở chỗ **chuỗi trước và sau một mốc khác nhau**. Cần tìm những mốc đó.

Trực giác. Chia chuỗi thành các đoạn, mỗi đoạn tả bằng trung bình riêng. Càng chia nhiều đoạn, mỗi đoạn càng khóp, tới mức mỗi điểm một đoạn thì khóp hoàn hảo mà vô nghĩa. Vì vậy mỗi điểm gãy phải "trả phí": chỉ cắt khi cắt làm chi phí giảm nhiều hơn phí phải trả.

Ví dụ số nhỏ — tự tính tay. Mười số (10, 11, 10, 9, 10, 20, 21, 19, 20, 20) . Chi phí một đoạn = tổng bình phương khoảng cách tới trung bình đoạn.


Cách chia	Chi phí	Số điểm gãy
không cắt (trung bình 15)	$127 + 127 = \mathbf{254}$	0
cắt trước điểm thứ 6 (trung bình 10 và 20)	$2 + 2 = \mathbf{4}$	1
cắt thêm trước điểm thứ 4	$0,67 + 0,5 + 2 = \mathbf{3,17}$	2

Độc bảng. Đặt penalty $\beta = 3 \ln 10 \approx 6,9$ cho mỗi điểm gãy. Cắt lần đầu giảm chi phí 250, lớn hơn β : **đáng** cắt. Cắt thêm chỉ giảm 0,83: **không** đáng. PELT trả đúng một điểm gãy, trước điểm thứ sáu (ruptures in [5, 10] : đoạn đầu kết thúc ở vị trí năm).

$$\min_{K, \tau_1 < \dots < \tau_K} \sum_{k=0}^K c(y_{\tau_k: \tau_{k+1}}) + \beta K$$

- K : số điểm gãy; τ_k : vị trí điểm gãy; $c(\cdot)$: chi phí một đoạn; β : penalty cho mỗi điểm gãy.

Nói bằng lời. Chọn số điểm gãy và vị trí sao cho tổng chi phí các đoạn cộng penalty nhỏ nhất. Ở ví dụ: một điểm gãy cho $4 + 6,9 = 10,9$; không cắt cho 254; hai điểm gãy cho $3,17 + 13,8 = 17,0$. Một điểm gãy thẳng.




Cách đọc hình. Trái: mười số và trung bình hai đoạn sau khi cắt một lần. Phải: chi phí (xanh) cộng phạt (cam) theo số điểm gãy K; một điểm gãy cho tổng nhỏ nhất, cột không cắt cao vượt khung.

PELT (Killick và cộng sự, 2012) tìm đúng lời giải tốt nhất, nhưng bỏ sót những vị trí chắc chắn không thẳng, nên chạy gần tuyến tính theo độ dài chuỗi.

Hai quyết định quan trọng hơn cả thuật toán.

1. **Biến đổi trước khi chạy.** Chi phí trên cộng bình phương, nên đo bằng **đơn vị của chuỗi**. Chuỗi tăng trưởng có dao động tỷ lệ với mức: năm đông khách thì mỗi dao động mùa vụ cũng "đắt", và PELT cắt ở mỗi mùa. Lấy log trước.
2. **Chọn penalty.** Quy ước hay dùng: khoảng $2 \ln n$ tới $3 \ln n$. Đừng tin một con số: **quét** nhiều penalty và giữ kết quả không đổi trong một khoảng rộng. Số điểm gãy phải **giảm dần** khi penalty tăng; không giảm là gọi sai API.

PELT: hai quyết định quyết định kết quả — biến đổi trước khi chạy, và chọn penalty



Cách đọc hình.


1. **Trục ngang:** ô trái là năm 2008 → 2026; ô phải là penalty chia $\ln n$.
2. **Trục dọc:** ô trái là hành khách mỗi tháng (triệu); ô phải là số điểm gãy tìm được.
3. **Ký hiệu:** ô trái, xám là chuỗi, vạch cam mờ là điểm gãy trên mức gốc, vạch xanh đậm là điểm gãy trên log; ô phải, mỗi chấm một penalty.
4. **Nhìn vào đầu:** số vạch cam so với vạch xanh; đoạn nằm ngang ở ô phải.
5. **Kết luận:** mức gốc cho 43 điểm gãy, gần như mỗi mùa hè một cái; log chỉ cho 2, và giữ nguyên trong cả khoảng penalty từ $1 \ln n$ tới $4 \ln n$; penalty lớn hơn nữa thì không còn điểm gãy nào.

Điểm gãy (trên log)	12 tháng trước (triệu khách/tháng)	12 tháng sau	Đổi
2/2020	86,4	18,4	-78,7%
5/2021	12,8	43,2	+238,2%

Độc bản. Hai điểm gãy là sụt COVID và hồi phục; độ lớn nói rõ đây là dịch mức cỡ lớn, không phải vài tháng lạ.

Khi nào dùng, khi nào không. Dùng PELT khi đã có cả chuỗi (làm sạch lịch sử, giải thích quá khứ). Không dùng nó để báo động khi dữ liệu đang về từng ngày: nó cần cả chuỗi và kết quả cũ có thể đôi khi thêm điểm mới.

Nâng cao — có thể bỏ qua lần đọc đầu. CUSUM cộng dồn độ lệch so với mức tham chiếu, $S_t = \max(0, S_{t-1} + y_t - \mu_0 - k)$. Nó báo động khi S_t vượt ngưỡng h , và chạy được trong lúc dữ liệu đang về, nên hợp để theo dõi mô hình đang chạy (buổi 42). **Binary Segmentation** tìm một điểm gãy tốt nhất, cắt đôi, lặp lại: nhanh nhưng tham lam. `ruptures` chưa có CROPS (thuật toán quét toàn bộ dải penalty của Haynes và cộng sự, 2017), nên buổi này tự quét.



Cách đọc hình. Trên: chuỗi, mức nhích lên nhẹ ở vạch xám. Dưới: tổng cộng dồn nằm sát 0, sau vạch xám leo đều và vượt ngưỡng h (nét đỏ) sau vài bước — báo động ngay khi dữ liệu đang về.

Tóm lại. Điểm gãy là mốc mà trước và sau khác nhau. PELT cắt chuỗi sao cho chi phí các đoạn cộng penalty nhỏ nhất: mỗi điểm gãy phải giảm chi phí nhiều hơn penalty. Lấy log trước với chuỗi tăng trưởng, và quét penalty.

Tự kiểm tra. Ở ví dụ 10 số, penalty phải lớn cỡ nào thì PELT không cắt lần nào?

Đáp án (tự làm trước rồi mới đọc)



Cắt một lần giảm chi phí $254 - 4 = 250$. Penalty **trên 250** thì cắt không còn lợi: PELT trả 0 điểm gãy. Nhầm hay gặp: nghĩ penalty là "số điểm gãy tối đa"; penalty là giá của mỗi điểm gãy, tính cùng đơn vị với chi phí.

4.6 COVID: coi là gì thì dự báo ra thế đó

Vấn đề. Giai đoạn 3/2020 – 6/2021 của hàng không EU là ngoại lai, dịch mức, hay "bình thường mới"? Mỗi câu trả lời dẫn tới một cách xử lý dữ liệu, và một dự báo khác.

Cách đo. Học tới hết 2022, dự báo 12 tháng 2023. Mô hình cố định: mùa vụ nhân (mỗi tháng là một tỷ lệ của xu hướng) + xu hướng thẳng, ước lượng trên **toàn bộ** phần học. Chỉ đổi cách xử lý giai đoạn COVID.

COVID là ngoại lai hay điểm gãy? Câu trả lời khác nhau đối hẳn kết quả dự báo



Cách đọc hình.

- Trục ngang:** ô trái là năm 2008 → 2026; ô phải là MAPE trên 12 tháng 2023 (%).
- Trục dọc:** ô trái là chuỗi hành khách (triệu mỗi tháng); ô phải là ba cách xử lý.
- Ký hiệu:** ô trái, vùng cam là giai đoạn COVID, vạch đen là mốc chia học/kiểm; ô phải, mỗi thanh một cách.
- Nhìn vào đâu:** độ dài ba thanh.
- Kết luận:** coi COVID là thiếu rồi nội suy cho sai số nhỏ nhất (8,71%); giữ nguyên tệ nhất (24,01%).

Cách xử lý	Số tháng học	MAPE 2023	Sai số trung bình (triệu khách/tháng)
giữ nguyên	180	24,01%	+19,7
coi là thiếu, nội suy	180	8,71%	+7,6
cắt, chỉ dùng sau hồi phục	18	18,11%	−12,9

Đọc bảng. Giữ nguyên: mười sáu tháng sụt kéo cả đường xu hướng xuống, dự báo thấp hơn thực tế gần 20 triệu mỗi tháng (sai số dương). Cắt: chỉ còn một năm rủi dữ liệu, hệ số mùa vụ ước lượng thô, và đà hồi phục bị kéo dài quá tay (sai số âm, dự báo cao hơn thực tế). Hyndman & Rostami-Tabar (2024) cũng khuyên coi giai đoạn gián đoạn là thiếu khi chỉ cần dự báo **sau** gián đoạn.

Khi nào dùng, khi nào không. Coi là thiếu khi sự kiện đã qua và hành vi quay về như cũ. Không dùng khi cần dự báo **trong** lúc gián đoạn, hay khi hành vi sau đó đổi hẳn: khi ấy dùng biến giả cho giai đoạn đó hoặc chỉ học phần sau, và cân nhắc gộp nhiều cách (ensemble).

Tóm lại. Cách xử lý một đoạn bất thường là một giả định về tương lai. Đo nó bằng dự báo thật trên kỳ chấm, và ghi giả định vào báo cáo.

Tự kiểm tra. Một chuỗi bán hàng có dịch mức lên vĩnh viễn từ tháng 6 (mở thêm chi nhánh). Coi đoạn sau tháng 6 là "thiếu rồi nội suy" có hợp không?

Đáp án (tự làm trước rồi mới đọc)

Không. Mức mới là thật và kéo dài; nội suy sẽ xoá nó, và dự báo quay về mức cũ. Dùng biến giả dịch mức, hoặc chỉ học phần sau tháng 6 nếu đủ dài. Nhầm hay gặp: thấy cách "coi là thiếu" thắng ở COVID rồi dùng cho mọi đoạn lạ; nó chỉ hợp khi hành vi quay về như cũ.

5. Lab từng bước

Lệnh gõ trong terminal ở thư mục `lab/`. Code các bước nằm sẵn trong `code/lab.ipynb` (mở bằng `python lab.py notebook` hoặc VS Code), chạy từng ô từ trên xuống. Bạn sửa `code/bat_thuong.py`; notebook tự nạp lại bản mới.

Bước 1 — Ngưỡng toàn chuỗi so với cửa sổ trượt

Mục đích: thấy masking trên dữ liệu thật và so năm cách bắt ngoại lai.

```
python lab.py up          # một lần: môi trường + dữ liệu (Wikipedia, Eurostat), kiểm sha256
python lab.py check       # 4/12 test đồ
python lab.py notebook    # chạy ô bước 1
```

Độc kết quả: bảng năm cách như mục 4.3; phép thử masking in $16 \rightarrow 5$ cho 3σ và $121 \rightarrow 123$ cho Hampel. Viết một câu: bạn chọn cách nào để làm sạch chuỗi này, vì sao.

Bước 2 — Tết: sự kiện thật

Mục đích: sửa `xu_ly_ngoai_lai` theo mục 4.4: (a) gán cờ bằng `hampel`, (b) winsorize (`y.where(~co, trung_vi)`) thay vì xoá, (c) bỏ qua các mốc trong `bo_qua_su_kien`. Chạy lại ô bước 2.

Độc kết quả: 10 đỉnh Tết giữ nguyên giá trị; `bi_xoa` toàn `False`; số mốc không đổi.

Bước 3 — PELT và penalty

Mục đích: sửa `diem_gay` để lấy log khi `log=True` (mục 4.5). Chạy lại ô bước 3; ô chạy cả ví dụ 10 số.

Độc kết quả: ví dụ 10 số in `[5, 10]`; hàng không EU: 43 điểm gãy trên mức gốc, 2 trên log (2/2020 và 5/2021); hình quét penalty giảm dần và nằm ngang ở 2 như hình mục 4.5.

Bước 4 — Đổi phương sai trên phần dư

Mục đích: sửa `doi_phuong_sai`: tính trên phần dư STL robust, đo độ dao động bằng MAD thay độ lệch chuẩn (mục 4.3). Chạy lại ô bước 4.

Độc kết quả: trước khi sửa, `doi_phuong_sai` trả danh sách rỗng: trên chuỗi gốc, dao động mùa vụ tuần lớn hơn hẳn phần dao động bị đổi, nên không thấy gì. Sau khi sửa, nó chỉ ra đúng đoạn cài sẵn, và `danh_gia_nhan` cho đủ 6/6 đúng loại, như hình mục 4.1.

Bước 5 — Ba cách xử lý COVID

Mục đích: chạy `ba_cach_xu_ly_covid` (mục 4.6), không cần sửa. Rồi:

```
python lab.py check      # 12/12 xanh
```

Độc kết quả: bảng như mục 4.6. Viết ba câu khuyến nghị, mỗi câu kèm điều kiện áp dụng. Xanh 12/12 là xong.

6. Lỗi thường gặp & cách chẩn đoán

Triệu chứng	Nguyên nhân	Chẩn đoán	Sửa
3ơ gần như không bắt được gì	masking; mẫu nhỏ; chuỗi có xu hướng	thêm một điểm cực lớn, xem số cờ có giảm không	MAD, Hampel
Mất đỉnh lễ sau khi làm sạch	coi sự kiện thật là lỗi	vẽ chuỗi quanh mốc bị sửa	nhật ký sự kiện
Chuỗi thùng mốc sau khi làm sạch	xoá thay vì winsorize	đếm số mốc trước/sau	<code>y.where(~co, trung_vi)</code>
STL không học được đỉnh Tết	Tết theo lịch âm	ngày trong năm của đỉnh theo năm	biến giả lịch âm (buổi 13)
PELT ra hàng chục điểm gãy	chuỗi tăng trưởng chạy trên mức gốc	so số điểm gãy trên log và trên mức gốc	lấy log trước
Số điểm gãy tăng khi penalty tăng	gọi sai API	quét và kiểm tính giảm dần	<code>predict(pen=...)</code>
Không tìm thấy điểm gãy nào	penalty quá lớn	quét từ $0,5 \ln n$	chọn trong khoảng ổn định
Bắt hụt "đổi phương sai"	đo trên chuỗi gốc: biên độ mùa vụ át mất; độ lệch chuẩn bị điểm đơn kéo	đo lại bằng MAD trên phần dư	phần dư STL + MAD
"Cắt dữ liệu cũ" làm sai số tăng	phần còn lại quá ngắn để ước lượng mùa vụ	đếm số năm còn lại	giữ dữ liệu + biến giả
MAD bằng 0	hơn nửa số điểm bằng nhau	<code>(y - y.median()).abs().median()</code>	bỏ qua điểm, hoặc cửa sổ dài hơn

7. Bài tập về nhà

1. **Cửa sổ Hampel.** Quét cửa sổ 5, 10, 15, 30, 60 ngày trên lượt xem Wikipedia; vẽ số ngày gần cờ theo cửa sổ. Cửa sổ nào hợp lý, dựa vào đâu?
2. **Isolation Forest.** Chạy `sklearn.ensemble.IsolationForest` trên chuỗi mô phỏng; so số nhân đúng với `dan_nhan`. Nó thiếu thông tin gì mà các cách của buổi này có?
3. **Nhật ký sự kiện thật.** Tìm 5 ngày lượt xem Wikipedia cao nhất **không** phải Tết, tra xem hôm đó có sự kiện gì, và quyết định giữ hay sửa từng ngày. Ghi lý do.

8. Tiêu chí "Xong khi"

- [] `python lab.py check` xanh 12/12.
- [] Tính tay được z-score, điểm MAD và quyết định cắt của PELT trên một dãy 10 số.
- [] Nộp bằng chứng masking bằng số ($16 \rightarrow 5$ và $121 \rightarrow 123$) và giải thích bằng lời.
- [] Giải thích vì sao 10/10 đỉnh Tết bị gần cờ mà không được sửa.
- [] Nộp hai điểm gãy COVID kèm độ lớn và khoảng penalty mà chúng ổn định.
- [] Ba cách xử lý COVID với MAPE thật, và khuyến nghị kèm điều kiện áp dụng.

9. Đọc thêm

- Killick, R., Fearnhead, P. & Eckley, I.A. (2012). Optimal detection of changepoints with a linear computational cost. *JASA* 107(500).
- Truong, C., Oudre, L. & Vayatis, N. (2020). Selective review of offline change point detection methods. *Signal Processing* 167.
- [ruptures](https://centre-borelli.github.io/ruptures-docs/) 1.1.10 — <https://centre-borelli.github.io/ruptures-docs/>
- Romano, G. — MATH337 *Changepoint detection: PELT, WBS and penalty choices* (Lancaster): https://www.lancaster.ac.uk/~romano/teaching/2425MATH337/4_algos_and_penalties.html
- Haynes, K., Eckley, I.A. & Fearnhead, P. (2017). Computationally efficient changepoint detection for a range of penalties (CROPS). *JCGS* 26(1).
- Hyndman, R.J. & Rostami-Tabar, B. (2024). Forecasting interrupted time series. *JORS* — <https://robjhyndman.com/papers/fits.pdf>
- Chen, C. & Liu, L.-M. (1993). Joint estimation of model parameters and outlier effects in time series. *JASA* 88(421).
- Rousseeuw, P.J. & Hubert, M. (2018). Anomaly detection by robust statistics. *WIREs Data Mining and Knowledge Discovery* 8(2).
- Wikimedia Pageviews API; Eurostat [avia_paoc](#).