

Buổi 11 — Ngoại lai và điểm gãy

1. Mục tiêu

Sau buổi này bạn:

- Phân biệt **bốn loại bất thường**: điểm đơn (AO), đổi mức (LS), thay đổi tạm (TC), đổi phương sai — và biết mỗi loại cần cách phát hiện khác nhau.
- Hiểu **masking**: vì sao chính ngoại lai làm ngưỡng 3σ mù, và chứng minh bằng số.
- Dùng **MAD** và **bộ lọc Hampel** (của số trượt) thay cho ngưỡng toàn chuỗi.
- Chấp nhận một sự thật khó chịu: **không có ngưỡng thống kê nào phân biệt được "lỗi đo" với "sự kiện thật"** — Tết là ví dụ.
- Chạy **PELT** để tìm điểm gãy, tự **quét penalty** và đọc elbow (vì `ruptures` không có CROPS).
- So ba cách xử lý COVID trên dữ liệu thật, và nói được cách nào tốt **cho mục đích nào**.

2. Nhắc lại buổi trước

- **Cờ truy vết** (buổi 10): mọi can thiệp vào dữ liệu phải để lại dấu vết (`da_dien`, `ngghi_ngo`). Hôm nay thêm `da_sua`.
- **Che nhân tạo để đánh giá**: muốn biết cách xử lý nào đúng thì phải có đáp án. Hôm nay dùng **chuỗi mô phỏng có nhãn** để chấm chính thuật toán phát hiện.
- **MAD** = $1,4826 \cdot \text{median}|y - \text{median}(y)|$ — buổi 10 dùng để ước lượng độ phân giải, hôm nay là nền của mọi ngưỡng bền vững.
- **Đừng trộn lỗi với tín hiệu**: dữ liệu "sạch" không phải dữ liệu "mượt".

3. Trạng thái đầu buổi

Sau `cd lab && make up`:

Hạng mục	Trạng thái
Dữ liệu 1	<code>wikipedia-vi-tong/</code> — 3.653 ngày tổng lượt xem <code>vi.wikipedia</code> , 2016-01-01 → 2025-12-31, sha256 <code>481d604d1b58</code>
Dữ liệu 2	<code>wikipedia-vi-tet/</code> — 3.653 ngày lượt xem bài "Tết Nguyên Đán", sha256 <code>8f9e15ea3055</code>
Dữ liệu 3	<code>eurostat-hanh-khach-hang-khong/</code> — 218 tháng hành khách hàng không EU27, 2008-01 → 2026-02, sha256 <code>6ce5178cf876</code>
Nguồn/giấy phép	Wikimedia Pageviews (CC0 1.0); Eurostat <code>avia_paoc</code> (CC BY 4.0)
Môi trường	Python 3.12.14; numpy 2.5.3, pandas 3.0.5, scipy 1.18.1, statsmodels 0.15.0, ruptures 1.1.10
<code>code/bat_thuong.py</code>	<code>z_score</code> , <code>iqr</code> , <code>mad_score</code> , <code>hampel</code> , <code>stl_robust</code> , <code>so_sanh_bat</code> , <code>masking</code> , <code>sinh_chuoi_co_loi</code> , <code>dan_nhan</code> , <code>doi_phuong_sai</code> , <code>diem_gay</code> , <code>quet_penalty</code> , <code>xu_lyngoai_lai</code> , <code>ba_cach_xu_ly_covid</code>
Đang cố tình sai	<code>xu_lyngoai_lai</code> xoá mọi điểm $> 3\sigma$ và không biết tới nhật ký sự kiện; <code>diem_gay</code> chạy PELT trên mức thô ; <code>doi_phuong_sai</code> đo trên chuỗi gốc bằng <code>std</code>


Hạng mục	Trạng thái
Triệu chứng	Chuỗi Tết mất sạch 10 đỉnh và thủng 54 mốc; hàng không EU27 ra 43 điểm gãy không ai giải thích nổi; cảnh báo "đổi phương sai" rải khắp nơi
make check lúc này	ĐỎ: 8/12 test qua, 4 test hồng

4. Lý thuyết

4.1 Bốn loại bất thường

Phân loại của Chen & Liu (1993), viết lại cho dễ nhớ:

Loại	Dấu hiệu	Ví dụ	Xử lý
AO — outlier cộng	một điểm lệch, trước sau như cũ	lỗi nhập liệu, sự cố đo	winsorize hoặc đánh dấu; không xoá mốc
LS — level shift	mức đổi và ở lại	đổi cách đo, mở thêm nhà máy, COVID	biến giả, hoặc cắt dữ liệu cũ
TC — thay đổi tạm	mức nhảy rồi hồi dần	khuyến mãi, bão, tin tức	biến giả có phân rã
đổi phương sai	mức giữ nguyên, biên độ đổi	đổi thiết bị, thị trường bất ổn	biến đổi Box-Cox, mô hình phương sai




Đọc hình. Chuỗi mô phỏng (seed 0) có 6 bất thường cài sẵn — sao đen là vị trí thật, vạch màu là nhãn thuật toán gán. Kết quả: **6/6 đúng loại**, kèm 3 cảnh báo giả. Chú ý điểm quan trọng: **Hampel một mình chỉ thấy AO** (nó so với mức địa phương, mà sau level shift thì mức địa phương cũng đổi theo). Muốn thấy LS/TC phải chạy **phát hiện điểm gãy**; muốn thấy đổi phương sai phải nhìn **phần dư**.

4.2 Vì sao ngưỡng toàn chuỗi hồng

$z_t = (y_t - \bar{y})/s$ có hai vấn đề.

Vấn đề 1 — masking. Chính ngoại lai kéo $\bar{y}$ và s lên, nên nó tự che mình và che các ngoại lai khác. Đo được trên lượt xem vi.wikipedia: thêm **một** điểm bằng $8 \times$ giá trị lớn nhất $\rightarrow$ số ngày bị 3σ gần cỡ tụt từ **16 xuống 5**. Cùng phép thử, Hampel đi từ 121 lên 123 — không bị ảnh hưởng. (Chiều ngược lại là **swamping**: ngoại lai làm các điểm bình thường bị gần cỡ oan.)


Masking: thêm một ngoại lai làm ngưỡng 3 σ dâng lên và CHE các ngoại lai khác (16 $\rightarrow$ 5 ngày); Hampel không đổi (121 $\rightarrow$ 123)



Độc hình. Cùng một chuỗi, cùng công thức 3 σ . Trái: ngưỡng nằm ở mức hợp lý, 16 ngày vượt. Phải: sau khi thêm **một** điểm rất lớn (điểm đó nằm ngoài khung hình), trung bình nhích lên và σ phình ra, kéo ngưỡng 3 σ lên cao đến mức chỉ còn **5 ngày** vượt qua. Mười một ngày "bất thường" vừa biến mất — không phải vì dữ liệu đổi, mà vì thước đo đổi.

Vấn đề 2 — chuỗi có xu hướng thì "trung bình toàn chuỗi" vô nghĩa.

Ngưỡng TOÀN CHUỖI mù trước chuỗi có xu hướng: mức tham chiếu phải là mức ĐỊA PHƯƠNG



Độc hình. Trên: 3 σ gắn cờ **16/3.653 ngày**, dồn hết vào vùng mức cao — nó chỉ đang nói "những ngày này đồng", không phải "những ngày này bất thường". Dưới: Hampel với cửa sổ trượt ± 15 ngày gắn **121 ngày**, rải đều suốt 10 năm, vì mức tham chiếu là **mức địa phương**.

Bảng đầy đủ:

Cách	Số ngày gắn cờ	Tỷ lệ
3 σ toàn chuỗi	16	0,44%
IQR 1,5	27	0,74%
MAD 3 (toàn chuỗi)	15	0,41%
Hampel k = 15	121	3,31%
STL robust (mùa vụ tuần)	616	16,86%

STL robust gắn cờ 16,86% — quá nhiều, vì phần dư của nó còn chứa cả mùa vụ năm mà mô hình chu kỳ tuần không giải thích được. Bài học: **ngưỡng nào cũng phải xem nó gắn cờ bao nhiêu phần trăm dữ liệu trước khi tin.**

4.3 MAD và bộ lọc Hampel

$$\text{MAD} = 1,4826 \cdot \text{median}_t |y_t - \text{median}(y)|$$

Hệ số 1,4826 đưa MAD về cùng thang với σ khi dữ liệu chuẩn. Điểm bền vững: $|y_t - \text{median}|/\text{MAD}$.


Hampel = đúng công thức đó nhưng trên **cửa sổ trượt**:

```
k = 2 * cua_so + 1
trung_vi = y.rolling(k, center=True, min_periods=cua_so).median()
mad = (y - trung_vi).abs().rolling(k, center=True, min_periods=cua_so).median()
co_co = (y - trung_vi).abs() / (1.4826 * mad) > 3
```

Hai tham số: **cửa sổ** (phải dài hơn biến động bình thường, ngắn hơn thay đổi cấu trúc) và **ngưỡng** (3 là quy ước, không thiêng liêng). Lưu ý `center=True` — bộ lọc này **không nhân quả** (buổi 12 sẽ đo). Với việc làm sạch lịch sử thì được; với feature dự báo thì phải dùng cửa sổ chỉ nhìn về quá khứ.

4.4 Sự thật khó chịu: Tết không phải ngoại lai

Sự kiện **THẬT**, không phải **lỗi**: xoá đi là xoá mất thứ đáng dự báo nhất — và STL không cứu được vì Tết theo lịch âm



Độc hình. Trái: lướt xem bài "Tết Nguyên Đán" 10 năm; vòng tròn đen là 10 đỉnh Tết thật, chấm cam là những ngày 3 σ gán cờ — **cả 10 đỉnh đều bị gán cờ**. Phải: mỗi đỉnh rơi vào ngày thứ 22-47 của năm dương lịch, **xê dịch 25 ngày** giữa các năm.

Đây là phần quan trọng nhất của buổi. Đo hết cả năm phương pháp:

Cách	Số đỉnh Tết bị gán cờ
3 σ toàn chuỗi	10/10
IQR 1,5	10/10
MAD 3	10/10
Hampel k = 15	10/10
STL robust (tuần)	10/10

Không phương pháp nào cứu được. Lý do rất đơn giản: xét về mặt thống kê, một đỉnh gấp 10 lần nền **đúng là** bất thường. Máy không thể biết đỉnh đó có ý nghĩa hay không.

Vì sao STL không cứu: Tết theo **lịch âm**, ngày dương xê dịch tới 25 ngày, nên mọi mô hình mùa vụ theo chu kỳ dương lịch cố định (365 ngày, 52 tuần) đều không khớp được. Cách sửa đúng là **nhật ký sự kiện**: một danh sách mốc "biết trước, không được động vào", và ở buổi 13 sẽ thành **biến giả lịch âm**.

```
dinh = dinh_tet(tet) # nhật ký sự kiện
xl = xu_ly_ngoai_lai(tet, bo_qua_su_kien=dinh) # đỉnh Tết được giữ nguyên
```

Và chú ý cách xử lý: **winsorize** (kéo về mức địa phương) chứ không **xoá**. Xoá mốc làm thùng lịch thời gian, và buổi 10 đã cho thấy một chuỗi thiếu mốc nguy hiểm thế nào.

4.5 Điểm gãy: PELT

Bài toán: chia chuỗi thành $K + 1$ đoạn sao cho tổng chi phí nội đoạn cộng phạt là nhỏ nhất:

$$\min_{K, \tau_1 < \dots < \tau_K} \sum_{k=0}^K c(y_{\tau_k:\tau_{k+1}}) + \beta K$$

với c là hàm chi phí (`l2` = phương sai quanh trung bình đoạn; `normal` = chi phí Gaussian, nhìn cả trung bình lẫn phương sai; `rbf` = phi tham số). **PELT** (Killick et al. 2012) giải tối ưu nhờ cắt tỉa: tài liệu `ruptures` viết "The algorithm relies on a pruning rule. Many indexes are discarded, greatly reducing the computational cost while retaining the ability to find the optimal segmentation", với độ phức tạp trung bình $\mathcal{O}(CKn)$.

Ba thuật toán hay gặp, ba đánh đổi:

Thuật toán	Cách làm	Ưu	Nhược
CUSUM	cộng dồn độ lệch so với mức tham chiếu, báo động khi tổng vượt ngưỡng	trực tuyến (online), rẻ, một dòng code	chỉ một điểm gãy mỗi lần chạy; cần biết mức tham chiếu
Binary Segmentation	tìm điểm gãy tốt nhất, cắt đôi, lặp lại	nhanh $\mathcal{O}(n \log n)$, dễ hiểu	tham lam — điểm gãy tìm trước có thể sai khi biết điểm sau
PELT	tối ưu toàn cục có cắt tỉa	tối ưu thật sự, vẫn tuyến tính	cần chọn penalty; offline (phải có cả chuỗi)


CUSUM đáng nhớ vì nó là thứ chạy được **trong lúc dữ liệu đang chảy về**:

$S_t = \max(0, S_{t-1} + (y_t - \mu_0) - k)$, báo động khi $S_t > h$. Trong giám sát mô hình sản xuất (buổi 42) ta sẽ dùng lại đúng ý tưởng này để phát hiện drift.

Hai quyết định quan trọng hơn cả thuật toán:

1. **Biến đổi trước khi chạy.** Chuỗi tăng trưởng nhân tính có phương sai tỷ lệ với mức; `l2` sẽ coi mỗi lần biên độ đổi là một điểm gãy mức.
2. **Chọn penalty β .** Quy ước: $BIC = 2 \log n$, $MBIC \approx 3 \log n$. Nhưng đừng tin một con số — hãy **quét**.

PELT: hai quyết định quyết định kết quả — biến đổi trước khi chạy, và chọn penalty



Độc hình. Trái: hành khách hàng không EU27. Vạch cam mờ = **43 điểm gãy** khi chạy PELT trên mức thô; vạch xanh đậm = **2 điểm gãy** khi lấy log trước. Phải: quét penalty — số điểm gãy giữ nguyên bằng 2 trong suốt khoảng **$1-4 \cdot \log n$** , đó là "elbow" ổn định. (Từ $5 \cdot \log n$ trở lên PELT trả **0** điểm gãy — đừng quét quá tay.)

Hai mốc tìm được và độ lớn thật của chúng:

Mốc	Trung bình 12 tháng trước	Trung bình 12 tháng sau	Đổi
2020-02	86,4 triệu	18,4 triệu	-78,7%
2021-05	12,8 triệu	43,2 triệu	+238,2%

Tháng đấy là 2020-04 với **890.607** khách so với 66.046.231 của 2020-01 — giảm **98,65%**.


`ruptures` **không có CROPS** (thuật toán quét toàn bộ dải penalty của Haynes et al. 2017), nên ta tự quét:

```
def diem_gay_on_dinh(y, khoang=(1.0, 4.0)):
    """Mốc nào xuất hiện ở MỌI penalty trong khoảng → đáng tin."""
```

Một phép kiểm rẻ để bắt lỗi cài đặt: **số điểm gãy phải giảm đơn điệu khi penalty tăng**. Nếu không, bạn đang gọi sai API.

4.6 COVID: ngoại lai, điểm gãy, hay bình thường mới?

Hyndman & Rostami-Tabar (2024) liệt kê các chiến lược cho chuỗi bị gián đoạn: "highly adaptable models, intervention models, **marking interrupted periods as missing**, forecasting what may have been, downweighting the interruption period, and ensemble models". Ta thử ba cách phổ biến nhất trên dữ liệu thật: học tới hết 2022, dự báo 12 tháng 2023.



Độc hình. Cùng chuỗi, cùng baseline (mùa vụ nhân + xu hướng tuyến tính ước lượng trên toàn bộ phần học):

Cách xử lý	Số kỳ học	MAPE 2023	Sai số trung bình
giữ nguyên	180	24,01%	-19,7 triệu khách/tháng
coi COVID là thiếu rồi nội suy	180	8,71%	-7,6 triệu
cắt, chỉ dùng sau hồi phục	18	18,11%	+12,9 triệu

Chênh nhau gần 3 lần chỉ vì một quyết định xử lý dữ liệu. Giải thích: giữ nguyên thì 15 tháng COVID kéo cả đường xu hướng xuống; cắt thì chỉ còn 18 tháng nên hệ số mùa vụ ước lượng rất thô và xu hướng phục hồi bị ngoại suy quá đà.

Kết quả này khớp đúng khuyến nghị của bài báo: **"The missing value approach is particularly useful when only post-interruption forecasts are required** and forecasts during the interruption period are not needed". Nhưng đừng đọc thành "luôn dùng cách 2": nếu cần dự báo *trong* giai đoạn gián đoạn, hoặc nếu hành vi sau gián đoạn thật sự khác hẳn, thì mô hình can thiệp hoặc mô hình thích nghi nhanh mới đúng. Bài báo cũng gợi ý **ensemble** khi không chắc chọn cách nào.

4.7 Sau khi tìm thấy thì làm gì — năm lựa chọn

Phát hiện mới là nửa việc. Năm cách xử lý, xếp từ nhẹ tới nặng:

Cách	Làm gì	Hợp với	Rủi ro
Giữ nguyên + đánh cờ	không sửa giá trị, chỉ thêm cột <code>nghi_ngo</code>	sự kiện thật; khi chưa chắc	mô hình không bền vững sẽ bị kéo lệch
Winsorize	kéo về mức địa phương (hoặc phân vị 1%/99%)	AO do lỗi đo	mất biên độ thật nếu gấn cờ nhầm
Coi là thiếu	đặt NaN rồi xử lý như buổi 10	đoạn dữ liệu hỏng dài	tạo lỗ; phải chọn cách điền
Biến giả	thêm cột 0/1 (hoặc có phân rã cho TC)	LS, TC, sự kiện lặp lại	cần biết mốc; nhiều biến giả dễ overfit
Cắt dữ liệu cũ	chỉ dùng phần sau điểm gãy	đổi cấu trúc thật sự	mất mẫu — đo được ở mục 4.6: 18 kỳ không đủ ước lượng mùa vụ

Quy tắc chọn: **loại bất thường quyết định cách xử lý, không phải độ lớn của nó**. Một AO lớn vẫn chỉ cần winsorize; một LS nhỏ vẫn cần biến giả, vì nó ảnh hưởng tới **mọi** dự báo về sau.

Và một nguyên tắc chung cho cả buổi: **luôn giữ số mốc**. Xoá dòng làm thủng lịch thời gian, phá `resample`, phá lag, và buổi 10 đã cho thấy loại lỗi đó khó thấy thế nào.

```
xl = xu_ly_ngoai_lai(tet, cach="hampel_winsorize", bo_qua_su_kien=dinh_tet(tet))
xl[["y", "sach", "da_sua", "bi_xoa"]] # bi_xoa phải toàn False
```

4.8 Nhặt kỹ sự kiện — thứ rẻ nhất và bị bỏ qua nhiều nhất

Mọi thứ trong buổi này quy về một việc: **ghi lại chuyện gì đã xảy ra**. Một bảng ba cột (mốc bắt đầu, mốc kết thúc, mô tả) cạnh dữ liệu cho phép bạn: giữ sự kiện thật, tạo biến giả đúng chỗ, giải thích điểm gãy thay vì đoán, và trả lời được "vì sao tháng đó lạ" khi sếp hỏi.

Cái máy không biết, và sẽ không bao giờ đoán được từ dữ liệu, là **ý nghĩa**. Đó là phần việc của bạn.

5. Lab từng bước

Bước 1 — Ngưỡng toàn chuỗi so với cửa sổ trượt

```
cd lab && make up
env -u VIRTUAL_ENV uv run --no-sync --project 00-nen python ../code/bat_thuong.py
make check # 4/12 dở
```

Chạy `so_sanh_bat(tong)` và `masking(tong)`. Giải thích vì sao 3σ chỉ bắt 16 ngày, và vì sao thêm một điểm làm con số đó **giảm**.

Bảng cần nộp có ba cột: tên cách bắt, số điểm gấn cờ, tỷ lệ %. Một cách gấn cờ **16 ngày** và một cách gấn cờ **616 ngày** đều đáng ngờ — cái đầu quá ít để hữu ích, cái sau nhiều tới mức "bất thường" trở thành "bình thường". Hãy nói rõ bạn chọn cách nào và vì sao.

Bước 2 — Tết: sự kiện thật

Chạy `mat_bao_nhiều_dinh_tet(tet)`. Sửa `xu_ly_ngoai_lai` để (a) winsorize thay vì xoá, (b) nhận `bo_qua_su_kien`. Kiểm: 10 đỉnh Tết giữ nguyên giá trị, số mốc không đổi.

Sau đó thử một việc nữa để tự thuyết phục mình: vẽ **ngày-trong-năm dương** của 10 đỉnh Tết theo năm (kết quả: 22–47, xê dịch 25 ngày), rồi chạy `stl_robust` với `chu_ky=365`. Mùa vụ dương lịch có học được đỉnh đó không? Ghi lại câu trả lời — buổi 13 sẽ dựng biến giả lịch âm để xử lý đúng chuyện này.

Bước 3 — PELT và penalty

Sửa `diem_gay` để lấy log trước khi chạy. Chạy `quet_penalty(hk)` và vẽ elbow. Báo cáo: hai mốc, độ lớn %, và khoảng penalty mà kết quả ổn định.

Bước 4 — Đối phương sai, và ba cách xử lý COVID

Sửa `doi_phuong_sai` (phần dư STL + MAD + `model="normal"`). Chạy `dan_nhan` trên chuỗi mô phỏng, đối chiếu `danh_gia_nhan` — phải đúng $\geq 4/5$ loại. Cuối cùng chạy `ba_cach_xu_ly_covid(hk)` và viết ba câu khuyến nghị.

make check

12/12 xanh

6. Lỗi thường gặp & cách chẩn đoán

Triệu chứng	Nguyên nhân	Chẩn đoán	Sửa
3ơ gấn như không bắt được gì	masking + chuỗi có xu hướng	thêm một điểm cực lớn, xem số cờ có giảm không	Hampel / MAD trên cửa sổ trượt
Ngoại lai "biến mất" sau khi thêm một điểm lớn	masking	như trên	ngưỡng bền vững
Mất đỉnh lễ Tết sau khi làm sạch	coi sự kiện thật là lỗi	vẽ chuỗi quanh mốc bị xoá	nhật ký sự kiện + winsorize
Chuỗi thùng mốc sau khi làm sạch	xoá thay vì winsorize	đếm số mốc trước/sau	<code>y.where(~co, trung_vi)</code>
STL không học được đỉnh Tết	Tết theo lịch âm, ngày dương xê dịch 25 ngày	vẽ ngày-trong-năm của đỉnh theo năm	biến giả lịch âm (buổi 13)
PELT ra hàng chục điểm gãy	chuỗi nhân tính chạy với l2	so số điểm gãy trên log và trên mức thô	lấy log (hoặc Box-Cox) trước
Số điểm gãy tăng khi penalty tăng	gọi sai API / nhầm đơn vị penalty	quét và kiểm tính đơn điệu	sửa lời gọi <code>predict(pen=...)</code>
Không tìm thấy điểm gãy nào	penalty quá lớn	quét từ $0,5 \cdot \log n$	chọn trong vùng elbow
Bắt hụt "đối phương sai"	đo trên chuỗi gốc, biên độ mùa vụ át ơ	so σ hai bên trên phần dư STL	phần dư + MAD + <code>model="normal"</code>

Triệu chứng	Nguyên nhân	Chẩn đoán	Sửa
Cảnh báo "đổi phương sai" khắp nơi	dùng <code>std</code> — một AO làm σ phình gấp 4	thay bằng MAD và xem còn lại bao nhiêu	MAD, ngưỡng tỷ lệ ≥ 2
Ba cách xử lý COVID cho kết quả y hệt	baseline chỉ dùng vài kỳ cuối	in số kỳ học và hệ số	ước lượng trên toàn bộ phần học
"Cắt bỏ dữ liệu cũ" làm sai số tăng	phần còn lại quá ngắn để ước lượng mùa vụ	đếm số chu kỳ còn lại	giữ dữ liệu + biến giả, hoặc ensemble

7. Bài tập về nhà

1. **Cửa sổ Hampel.** Quét `cua_so` $\in \{5, 10, 15, 30, 60\}$ trên lượt xem `vi.wikipedia`; vẽ số ngày gần cờ theo cửa sổ. Cửa sổ nào hợp lý, và bạn dựa vào đâu để nói vậy?
2. **Isolation Forest.** Chạy `sklearn.ensemble.IsolationForest` trên chuỗi mô phỏng; so số nhân đúng với `dan_nhan`. Nó thiếu thông tin gì mà các phương pháp chuỗi thời gian có?
3. **Nhật ký sự kiện thật.** Lập nhật ký cho lượt xem `vi.wikipedia`: tìm 5 ngày có đỉnh lớn nhất **không** phải Tết, tra xem hôm đó có sự kiện gì, và quyết định giữ hay sửa từng cái. Ghi lý do.

8. Tiêu chí "Xong khi"

- [] `make check` xanh 12/12.
- [] Trên chuỗi mô phỏng, gần đúng loại cho $\geq 4/5$ bất thường cài sẵn và bảo vệ được cách xử lý từng loại.
- [] Nộp bằng chứng masking bằng số ($16 \rightarrow 5$ và $121 \rightarrow 123$).
- [] Nộp bằng "10/10 đỉnh Tết bị gần cờ" kèm một đoạn giải thích vì sao **không** phương pháp thống kê nào sửa được.
- [] Nộp hai điểm gầy COVID kèm độ lớn % và khoảng penalty mà chúng ổn định.
- [] Ba cách xử lý COVID với MAPE thật, và khuyến nghị kèm điều kiện áp dụng.

9. Đọc thêm

- Killick, R., Fearnhead, P. & Eckley, I.A. (2012). Optimal detection of changepoints with a linear computational cost. *JASA* 107(500).
- Truong, C., Oudre, L. & Vayatis, N. (2020). Selective review of offline change point detection methods. *Signal Processing* 167.
- `ruptures` 1.1.10 — <https://centre-borelli.github.io/ruptures-docs/>
- Haynes, K., Eckley, I.A. & Fearnhead, P. (2017). CROPS. *JCGS* 26(1) — thuật toán quét dải penalty, chưa có trong `ruptures`.
- Hyndman, R.J. & Rostami-Tabar, B. (2024). Forecasting interrupted time series. *JORS* — <https://robjhyndman.com/papers/fits.pdf>
- Chen, C. & Liu, L.-M. (1993). Joint estimation of model parameters and outlier effects in time series. *JASA* 88(421).
- Hampel, F.R. (1974). The influence curve and its role in robust estimation. *JASA* 69(346).
- Wikimedia Pageviews API — <https://doc.wikimedia.org/generated-data-platform/aqs/analytics-api/>
- Eurostat `avia_paoc` — https://ec.europa.eu/eurostat/databrowser/view/avia_paoc