

Buổi 17 — ARIMA và SARIMA

1. Mục tiêu

Sau buổi này bạn:

- Nhận ra **AR(p)**, **MA(q)**, **ARMA** qua ACF và PACF, và nói giới hạn của cách đọc này.
- Tự chọn bậc **ARIMA** cho một chuỗi kinh tế tháng và **SARIMA** cho một chuỗi du lịch tháng, so AICc với auto-ARIMA.
- Kiểm phần dư bằng **Ljung-Box** (tính tay được), và nhận ra mô hình quên phần mùa vụ.
- Giải thích vì sao khoảng dự báo của ARIMA(0,1,0) nở theo $\sqrt{h}$.
- So AutoARIMA với AutoETS và seasonal naive trên 366 chuỗi bằng bộ backtest buổi 15, có kiểm định.

2. Nhắc lại buổi trước

Từ buổi 7 và 14:

- Tính dừng**: trung bình, độ dao động và tự tương quan không đổi theo thời gian. **Sai phân** $y_t - y_{t-1}$ khử xu hướng; **sai phân mùa vụ** $y_t - y_{t-12}$ khử mùa vụ tháng. KPSS: p nhỏ là không dừng.
- ACF** r_k : tương quan giữa chuỗi và chính nó dời k bước; vạch ngoài hai đường đứt $\pm 1,96/\sqrt{n}$ là đáng kể.
- Phần dư**: thực tế – giá trị khớp trên phần học. Mô hình đã lấy hết quy luật thì phần dư không tự tương quan.
- Ljung-Box** (buổi 14): kiểm định gộp ACF của nhiều trễ; p nhỏ là phần dư còn tự tương quan.

Từ buổi 15–16:

- Backtest**, **Diebold-Mariano (DM)**, **MASE** như buổi 15; các chuỗi độc lập nên DM trên chênh MASE của nhiều chuỗi dùng $h = 1$.
- AICc**: chọn mô hình theo độ khớp có phạt số tham số; nhỏ hơn là tốt hơn. **AutoETS** trên 366 chuỗi du lịch: MASE 1,581, thắng seasonal naive (1,720) có ý nghĩa.

3. Trạng thái đầu buổi

Sau `python lab.py up` (trong thư mục `lab/`):

Hạng mục	Trạng thái
Dữ liệu 1	<code>du-lieu/raw/frb-g17-san-luong-cong-nghiep/g17-2000-2024.csv</code> — chỉ số sản lượng công nghiệp Mỹ theo tháng, đã khử mùa vụ, 1/2000 → 12/2024, sha256 <code>3956c6626866</code> ; buổi này dùng tới 12/2019
Dữ liệu 2	<code>monash-tourism-monthly/tourism_monthly_dataset.tsf (fba16c20b9c4)</code> — 366 chuỗi khách du lịch theo tháng
Nguồn	Federal Reserve Board G.17 (public domain); Monash Time Series Forecasting Repository (CC BY 4.0)
Môi trường	Python 3.12; numpy 2.5.3, pandas 2.3.3, statsmodels 0.15.0, statsforecast 2.1.1

Hạng mục	Trạng thái
code/arima.py	đọc dữ liệu, <code>mo_phong</code> , <code>acf_pacf</code> , <code>arima</code> , <code>auto_arima</code> , <code>ljung_box</code> , <code>kiem_phan_du</code> , <code>mo_hinh_tu_chon</code> , <code>bang_ung_vien</code> , <code>du_bao</code> , <code>backtest_tourism</code> , <code>so_sanh</code>
code/lab.ipynb	notebook của Lab, bước 1-5
Đang cố tình sai	<code>MUA_VU_ARIMA = 1</code> (auto-ARIMA không biết chu kỳ 12); <code>kiem_phan_du</code> không kiểm gì, luôn báo "ổn"; <code>mo_hinh_tu_chon</code> mặc định không có phần mùa vụ
Triệu chứng	auto-ARIMA chọn mô hình không mùa vụ cho chuỗi du lịch; mọi mô hình đều "phần dư ổn"; backtest: AutoARIMA thua cả seasonal naive
python lab.py check lúc này	ĐỎ: 3/6 test hỏng

4. Lý thuyết

Từ mới trong buổi

Thuật ngữ	Nghĩa một câu	Ví dụ
AR(p) (tự hồi quy)	Giá trị hôm nay = tổng có trọng số của p giá trị trước + nhiễu.	AR(1): $y_t = 0,5 y_{t-1} + \varepsilon_t$.
MA(q) (trung bình trượt của nhiễu)	Giá trị hôm nay = nhiễu hôm nay + tổng có trọng số của q cú nhiễu trước.	MA(1): $y_t = \varepsilon_t + 0,8 \varepsilon_{t-1}$.
ARMA(p, q)	Có cả phần AR và phần MA.	ARMA(1,1).
nhiễu trắng	Dãy cú nhiễu độc lập, trung bình 0, không tự tương quan.	ε_t .
PACF (tự tương quan riêng phần)	Tương quan giữa y_t và y_{t-k} sau khi đã trừ phần giải thích được bởi các trễ 1 tới $k-1$.	AR(2): PACF tắt sau trễ 2.
ARIMA(p, d, q)	ARMA trên chuỗi đã sai phân d lần.	ARIMA(0,1,1).
drift	Hằng số trong mô hình có $d = 1$: chuỗi tăng trung bình một lượng cố định mỗi kỳ.	+0,026% mỗi tháng.
SARIMA(p,d,q)(P,D,Q)m	ARIMA thêm phần AR, MA, sai phân ở trễ bội của chu kỳ m .	(0,1,1)(0,1,1)12.
auto-ARIMA	Thuật toán Hyndman-Khandakar: chọn d , D bằng kiểm định, rồi dò các bậc lân cận theo AICc.	<code>AutoARIMA(season_length=12)</code> .
bậc tự do (Ljung-Box)	Số trễ gộp trừ số tham số AR, MA đã ước lượng.	$24 - 2 = 22$.
SES, DM	Làm trơn hàm mũ đơn (buổi 16); kiểm định Diebold-Mariano (buổi 15).	SES = ARIMA(0,1,1).

4.1 AR, MA, ARMA và dấu vân tay trên ACF/PACF

Vấn đề. ETS mô tả chuỗi bằng mức, xu hướng, mùa vụ. Có cách thứ hai: mô tả trực tiếp **tự tương quan** của chuỗi, tức hôm nay phụ thuộc hôm qua thế nào. Cần biết mô hình nào sinh ra dạng tự tương quan nào, để nhìn ACF mà đoán.

Trực giác. AR: chuỗi "nhớ" giá trị của chính nó, nên một cú sốc tắt dần qua nhiều kỳ. MA: chuỗi chỉ nhớ **cú nhiễu** trong q kỳ, sau đó quên hẳn.

Ví dụ số nhỏ — tự tính tay.

- AR(1), $y_t = 0,5 y_{t-1} + \varepsilon_t$, trung bình 0, hôm nay $y = 8$. Dự báo nhân 0,5 mỗi bước: $8 \times 0,5 = 4$, rồi $4 \times 0,5 = 2$.
- ACF của AR(1) là $r_k = 0,5^k$, tắt dần. PACF bằng 0,5 ở trễ 1 rồi bằng 0, vì khi đã biết y_{t-1} thì y_{t-2} không thêm gì.
- MA(1), $y_t = \varepsilon_t + 0,8 \varepsilon_{t-1}$: y_t và y_{t-1} chung cú nhiễu ε_{t-1} , còn y_t và y_{t-2} không chung gì. ACF: $r_1 = 0,8/(1 + 0,8^2) \approx 0,49$, $r_2 = 0$ (tắt hẳn sau trễ 1).

Mô hình	ACF	PACF
AR(p)	tắt dần	tắt hẳn sau trễ p
MA(q)	tắt hẳn sau trễ q	tắt dần
ARMA(p, q)	tắt dần	tắt dần

Đọc bảng. Nhìn cái nào tắt hẳn: PACF tắt hẳn → AR, bậc bằng trễ cuối còn đáng kể; ACF tắt hẳn → MA. Cả hai tắt dần → ARMA, và bảng không cho biết bậc.


Công thức.

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

- ϕ_i : hệ số AR; θ_j : hệ số MA; ε_t : nhiễu trắng; c : hằng số.

Nói bằng lời. Hôm nay = hằng số + phần nhớ các giá trị trước + cú nhiễu hôm nay + phần nhớ các cú nhiễu trước. Ở AR(1) trên: $0 + 0,5 \times 8 = 4$ là dự báo bước tới. AR(1) chỉ **dừng** khi $|\phi_1| < 1$ (nếu không, cú sốc không tắt); MA(1) cần $|\theta_1| < 1$ để ước lượng được duy nhất (khả nghịch).

AR(p): PACF tắt sau p trễ; MA(q): ACF tắt sau q trễ; ARMA: cả hai tắt dần



Cách đọc hình.

1. **Trục ngang** (mọi ô): trễ 1 → 12.
2. **Trục dọc:** hàng trên là ACF, hàng dưới là PACF, từ -1 tới 1.
3. **Ký hiệu:** mỗi cột một mô hình mô phỏng 500 điểm (seed 1); đường đứt đen là $\pm 1,96/\sqrt{n}$.
4. **Nhìn vào đầu:** ô nào có cột rơi hẳn vào trong hai đường đứt sau vài trễ đầu.
5. **Kết luận:** AR(2) có hai cột PACF đáng kể rồi tắt; MA(1) có một cột ACF (gần giá trị tính tay) rồi tắt; ARMA(1,1) tắt dần ở cả hai hàng.

Khi nào dùng, khi nào không. Đọc ACF/PACF để có điểm xuất phát và kiểm lại mô hình auto-ARIMA chọn có hợp lý không. Không dùng nó làm công cụ chọn duy nhất: với ARMA, hay khi mẫu ngắn (dưới khoảng 100 điểm, các cột dao động nhiều), đầu vùn tay mờ đi.

Tóm lại. AR nhớ giá trị cũ (PACF tắt sau p), MA nhớ cú nhiều cũ (ACF tắt sau q). ARMA tắt dần ở cả hai, nên ACF/PACF không đọc được bậc: khi đó để AICc chọn.

Tự kiểm tra. ACF chỉ có trễ 1 đáng kể (0,4), các trễ sau gần 0. PACF tắt dần và đổi dấu. Mô hình gì?

Đáp án (tự làm trước rồi mới đọc)


MA(1): ACF tắt hẳn sau trễ đầu, PACF tắt dần (đổi dấu). Nhầm hay gặp: thấy PACF trễ 1 lớn rồi đoán AR(1); với AR(1) có $\phi = 0,4$ thì ACF phải tắt dần theo lũy thừa của 0,4, không rơi về 0 ngay. Và MA(1) không bao giờ cho ACF đầu tiên quá một nửa.

4.2 ARIMA: sai phân rồi ARMA

Vấn đề. Chuỗi kinh tế thường có xu hướng, không dừng; ARMA chỉ dùng cho chuỗi dừng. Sai phân (buổi 7) biến nó thành dừng; "I" trong ARIMA là số lần sai phân d .

Ví dụ số nhỏ — tự tính tay. Chỉ số (100, 102, 103, 105, 106). Sai phân một lần: (2, 1, 2, 1), dao động quanh 1,5: dừng. Nếu phần sai phân là AR(1) với hằng số, dự báo tăng trưởng tháng sau rồi cộng dồn vào mức cuối 106.

Dữ liệu thật. Chỉ số sản lượng công nghiệp Mỹ 1/2000 → 12/2019 (240 tháng, đã khử mùa vụ). Lấy $100 \times \ln$ để sai phân thành tăng trưởng tháng tính bằng %.



Cách đọc hình.

- Trục ngang:** ô trái là thời gian 2000 → 2019; hai ô phải là trễ 1 → 12.
- Trục dọc:** ô trái là tăng trưởng tháng (%); hai ô phải là ACF và PACF.
- Ký hiệu:** đường đứt là $\pm 1,96/\sqrt{n} \approx 0,13$.
- Nhìn vào đâu:** vị trí trễ cuối cùng mà PACF còn vượt đường đứt.
- Kết luận:** ACF tắt dần; PACF còn đáng kể tới trễ 4 (0,21) rồi rơi về 0,02: đọc ra AR(4) trên chuỗi sai phân, tức ARIMA(4,1,0).

Mô hình (cùng $d = 1$, có drift)	AICc	Ljung-Box p
ARIMA(1,1,0)	466,9	0,000
ARIMA(4,1,0), đọc từ PACF	437,2	0,44
ARIMA(1,1,1)	445,0	0,15

Mô hình (cùng $d = 1$, có drift)	AICc	Ljung-Box p
ARIMA(2,1,2)	433,6	0,78
auto-ARIMA $\rightarrow$ ARIMA(2,1,2)	431,8	0,78

Độc bảng. AR(4) đọc từ PACF qua được Ljung-Box, nhưng AICc kém auto-ARIMA 5,4 đơn vị: auto-ARIMA tìm ra một ARMA(2,2), loại mô hình mà PACF không đọc được bậc (mục 4.1). Hai dòng cuối cùng bậc; auto-ARIMA bỏ drift nên AICc thấp hơn một chút.

Khi nào dùng, khi nào không. Chỉ so AICc giữa các mô hình có cùng d (và D): sai phân khác nhau là dữ liệu khác nhau, likelihood không so được (sách FPP của Hyndman & Athanasopoulos, §9.6). Đọc ACF/PACF để có điểm xuất phát và hiểu mô hình; để AICc và Ljung-Box quyết định.

Tóm lại. ARIMA(p,d,q) = sai phân d lần rồi ARMA(p,q). ACF/PACF cho điểm xuất phát; AICc chọn trong các mô hình cùng d ; Ljung-Box xác nhận phần dư sạch.

Tự kiểm tra. Hai mô hình: ARIMA(1,1,1) AICc 300 và ARIMA(1,0,1) AICc 280. Kết luận ARIMA(1,0,1) tốt hơn được không?

Đáp án (tự làm trước rồi mới đọc)

Không: khác d nên hai AICc tính trên hai dữ liệu khác nhau (chuỗi gốc và chuỗi sai phân). Chọn d trước bằng kiểm định (KPSS, buổi 7), rồi mới so AICc. Nhầm hay gặp: so AICc của mọi mô hình trong một bảng.

4.3 SARIMA và auto-ARIMA

Vấn đề. Chuỗi du lịch theo tháng có mùa vụ năm: tháng này giống tháng này năm ngoái. ARIMA thường chỉ nhìn vài tháng gần; cần thêm phần nhìn cách 12, 24 tháng.

Trực giác. SARIMA là hai ARIMA lồng nhau: một cho quan hệ giữa các tháng liền nhau (p, d, q), một cho quan hệ giữa cùng tháng các năm (P, D, Q) với chu kỳ $m = 12$. Sai phân mùa vụ $D = 1$ là trừ cùng tháng năm trước.


Ví dụ số nhỏ — tự tính tay. Chuỗi (10, 20, 11, 21, 12, 22) với $m = 2$: sai phân mùa vụ $y_t - y_{t-2} = (1, 1, 1, 1)$: mùa vụ biến mất, còn lại mức tăng 1 mỗi vòng. Mô hình $(0,1,1)(0,1,1)_m$: sai phân thường và sai phân mùa vụ, rồi một MA ở trễ 1 và một MA ở trễ m .

Dữ liệu thật: chuỗi du lịch T33. 306 tháng (bỏ 24 tháng cuối), lấy log, rồi sai phân mùa vụ và sai phân thường. ACF của chuỗi đó:

Trễ	1	2	11	12	13	24
ACF	-0,53	0,09	0,31	-0,39	0,17	-0,06

Độc bảng. Hai gai âm ở trễ đầu và trễ bằng chu kỳ. Hai trễ kề bên gai chu kỳ là "vệt" của hai gai: một gai nối các tháng liền nhau, gai kia nối cùng tháng năm trước, gộp lại nối cả các tháng cách một năm cộng trừ một tháng. Trễ hai chu kỳ đã về 0. Gai ACF tắt hẳn $\rightarrow$ MA: MA(1) và MA mùa vụ(1), tức SARIMA(0,1,1)(0,1,1)₁₂, mô hình "airline" kinh điển.

Chuỗi du lịch T33: gại ở trễ 1 và 12 → MA(1) và MA mùa vụ(1); quên phần mùa vụ thì phần dư còn gại ở 12



Cách đọc hình.

1. **Trục ngang** (ba ô): trễ 1 → 26.
2. **Trục dọc**: ACF.
3. **Ký hiệu**: ô trái là chuỗi sau hai lần sai phân; ô giữa là phần dư của ARIMA(0,1,1) (quên mùa vụ); ô phải là phần dư của SARIMA(0,1,1)(0,1,1)12.
4. **Nhìn vào đâu**: cột ở trễ 12 và 24 của từng ô.
5. **Kết luận**: quên mùa vụ, phần dư có ACF 0,84 ở trễ 12: quy luật mùa vụ còn nguyên; thêm phần mùa vụ thì mọi cột nằm gần hai đường đứt.

Mô hình trên log T33	AICc	Ljung-Box p (24 trễ)
ARIMA(0,1,1), quên mùa vụ	181,0	≈ 0
SARIMA(0,1,1)(0,1,1)12, đọc từ ACF	-435,2	0,34
auto-ARIMA → SARIMA(0,1,1)(0,1,2)12	-436,1	0,31

Đọc bảng. Mô hình đọc tay qua Ljung-Box và AICc chỉ cách auto-ARIMA dưới 1 đơn vị (cùng d , cùng D): gần như tương đương. Dòng đầu khác D nên AICc không so được; Ljung-Box một mình đã đủ loại nó. Hệ số mô hình đọc tay: MA(1) -0,735, MA mùa vụ -0,531.

auto-ARIMA (Hyndman & Khandakar 2008; FPP §9.7): chọn D theo độ mạnh mùa vụ, chọn d bằng các kiểm định KPSS lặp lại, rồi bắt đầu từ vài mô hình nhỏ và dò các bậc lân cận (± 1) theo AICc tới khi không tốt hơn. Trong statsforecast, `AutoARIMA` mặc định `season_length=1`: nếu không khai chu kỳ 12, nó không bao giờ thử phần mùa vụ.

Tóm lại. SARIMA thêm sai phân và AR/MA ở các trễ bội của chu kỳ. Gai ACF ở trễ 12 của chuỗi đã sai phân là dấu hiệu cần MA mùa vụ; quên phần mùa vụ thì phần dư còn gại đó. Với auto-ARIMA, luôn khai `season_length`.

Tự kiểm tra. Chuỗi theo quý ($m = 4$) sau sai phân thường và sai phân mùa vụ có ACF đáng kể ở trễ 1 và trễ 4, các trễ khác gần 0. Đề xuất mô hình.

Đáp án (tự làm trước rồi mới đọc)

SARIMA(0,1,1)(0,1,1)4: MA(1) cho gại ở trễ 1, MA mùa vụ(1) cho gại ở trễ 4. Nhảm hay gặp: viết (0,1,4) để "bắt" trễ 4 bằng MA thường, tốn 4 tham số thay vì 1.

4.4 Kiểm tra phần dư: Ljung-Box

Vấn đề. Một mô hình có AICc đẹp vẫn có thể bỏ sót quy luật. Cần một phép kiểm gộp: phần dư còn tự tương quan ở bất kỳ trễ nào không?

Ví dụ số nhỏ — tự tính tay. $n = 100$ phần dư, gộp hai trễ, mô hình không có tham số AR/MA:

Trễ k	1	2
ACF phần dư r_k	0,3	0,1

Độc bảng. Thay vào công thức dưới đây:

- $Q = 100 \times 102 \times (0,09/99 + 0,01/98) \approx 10,3$.
- So với phân phối chi-bình-phương hai bậc tự do (ngưỡng 5% là 5,99): $p \approx 0,006$.
- Phần dư còn tự tương quan.

Công thức.

$$Q = n(n+2) \sum_{k=1}^K \frac{r_k^2}{n-k}, \quad \text{bậc tự do} = K - (p + q + P + Q_m)$$

- n : số phần dư; r_k : ACF của phần dư ở trễ k ; K : số trễ gộp (dữ liệu tháng thường 24); p, q, P, Q_m : số hệ số AR, MA, AR mùa vụ, MA mùa vụ đã ước lượng.

Nói bằng lời. Cộng bình phương các ACF của phần dư (trễ xa được nhân nặng hơn một chút), nhân với cỡ mẫu. Phần dư là nhiễu trắng thì Q nhỏ cỡ số bậc tự do; lớn hơn nhiều thì còn quy luật. Ở ví dụ: 10,3 so với ngưỡng 5,99.

Thư viện. Hàm `ljung_box` tự viết khớp `statsmodels.stats.diagnostic.acorr_ljungbox(..., model_df=...)`. Bỏ $d + D \times m$ phần dư đầu (sai phân chưa đủ dữ liệu) trước khi kiểm.

Khi nào dùng, khi nào không. Chạy Ljung-Box cho mọi mô hình trước khi dùng nó, kèm nhìn ACF phần dư để biết gai nằm ở đâu. Không coi $p \geq 0,05$ là chứng minh mô hình đúng: nó chỉ nói không thấy tự tương quan; mẫu ngắn thì phép kiểm yếu.

Tóm lại. Ljung-Box gộp ACF của phần dư qua nhiều trễ thành một con số; $p < 0,05$ là mô hình còn bỏ sót quy luật. Trừ số tham số AR/MA khỏi bậc tự do.

Tự kiểm tra. Mô hình SARIMA có một hệ số AR, một hệ số MA, một hệ số MA mùa vụ; gộp hai mươi bốn trễ. Bậc tự do bao nhiêu? Ngưỡng 5% với số bậc tự do đó là 32,7; $Q = 40$ thì kết luận gì?

Đáp án (tự làm trước rồi mới đọc)

$24 - 3 = 21$. $Q = 40$ vượt 32,7; $p < 0,05$, phần dư còn tự tương quan, mô hình chưa đủ. Nhắm hay gặp: quên trừ số tham số, dùng 24 bậc tự do, p lớn hơn thật.

4.5 Khoảng dự báo của ARIMA

Vấn đề. ARIMA cho khoảng dự báo; khoảng đó nở ra thế nào theo tầm h , và vì sao?

Ví dụ số nhỏ — tự tính tay. ARIMA(0,1,0) là bước ngẫu nhiên: $y_t = y_{t-1} + \varepsilon_t$, dự báo mọi bước bằng giá trị cuối. Sai số h bước tới là tổng h cú nhiễu độc lập, phương sai $h\sigma^2$, độ lệch chuẩn $\sigma\sqrt{h}$. Với $\sigma = 2$:


- bước 1: $\pm 1,96 \times 2 = \pm 3,92$;
- bước 4: $\pm 1,96 \times 2 \times \sqrt{4} = \pm 7,84$, gấp đôi bước 1.

Công thức.

$$\hat{y}_{T+h} \pm 1,96 \sigma \sqrt{h} \quad (\text{ARIMA}(0,1,0))$$

- $\hat{y}_{T+h}$: dự báo h bước tới (bằng giá trị cuối); σ : độ lệch chuẩn của một cú nhiễu.

Nói bằng lời. Muốn khoảng rộng gấp đôi thì phải nhìn xa gấp bốn: bước 4 rộng gấp đôi bước 1, bước 16 gấp bốn.



Cách đọc hình.

1. **Trục ngang:** tháng của chuỗi T33 (60 tháng cuối và 24 tháng dự báo).
2. **Trục dọc:** số khách (nghìn), đổi ngược từ log.
3. **Ký hiệu:** đen là lịch sử; cam là ARIMA(0,1,0), xanh là SARIMA(0,1,1)(0,1,1)12; vùng mờ là khoảng 95%.
4. **Nhìn vào đâu:** độ rộng vùng cam ở đầu và cuối 24 tháng; dạng của đường xanh.
5. **Kết luận:** vùng cam rộng hơn hẳn và nở mãi; trên log, độ rộng ở bước 4 và 16 đúng gấp 2 và 4 lần bước 1. SARIMA hẹp hơn nhiều vì nó giải thích được nhịp mùa, phần còn lại nhỏ.

Khi nào dùng, khi nào không. Dùng khoảng của ARIMA khi phần dư đã qua Ljung-Box và gần hình chuông; nếu không, độ rộng tính theo công thức sẽ sai. Trên chuỗi đã lấy log, đổi ngược bằng hàm mũ thì khoảng lệch về phía trên, không còn đối xứng quanh dự báo.

Tóm lại. Khoảng dự báo của ARIMA nở theo tầm vì các cú nhiễu tương lai cộng dồn; với bước ngẫu nhiên, độ rộng tỷ lệ $\sqrt{h}$. Mô hình giải thích được nhiều hơn thì khoảng hẹp hơn, nhưng vẫn phải kiểm tỷ lệ phủ (buổi 16).

Tự kiểm tra. Bước ngẫu nhiên có khoảng 95% ở bước 1 là ± 5 . Khoảng ở bước 9 là bao nhiêu?

Đáp án (tự làm trước rồi mới đọc)

Nhân căn của 9: ± 15 . Nhầm hay gặp: nhân thẳng với 9; độ rộng nở theo căn của tầm, không theo tầm.

4.6 ARIMA hay ETS: so trên 366 chuỗi

Vấn đề. ETS và ARIMA là hai cách mô tả khác nhau; vài mô hình trùng nhau (SES là ARIMA(0,1,1)), đa số thì không. Cái nào tốt hơn?


Cách đo. Như buổi 16: bộ backtest buổi 15 trên 366 chuỗi du lịch, hai cửa sổ dự báo 24 tháng, MASE mỗi chuỗi, DM trên chênh MASE.

Mô hình	MASE trung bình	MASE trung vị
AutoARIMA (season_length=12)	1,574	1,430
AutoETS	1,581	1,392
seasonal naive	1,720	1,534
AutoARIMA quên mùa vụ (season_length=1)	2,791	2,284

So sánh	Chuỗi thắng	DM	p
AutoARIMA so với seasonal naive	68,6%	-7,26	< 0,0001
AutoETS so với seasonal naive	70,5%	-5,23	< 0,0001
AutoARIMA so với AutoETS	50,3%	-0,33	0,74

Độc bảng. Cả hai thắng seasonal naive có ý nghĩa; giữa chúng thì không có bên thắng. Quên chu kỳ 12, AutoARIMA thua cả seasonal naive (2,791 so với 1,720).

AutoARIMA và AutoETS cùng thắng seasonal naive; giữa hai cái không có bên thắng



Cách đọc hình.

- Trục ngang:** ô trái là ba mô hình; ô phải là MASE AutoARIMA trừ MASE AutoETS của từng chuỗi, cắt ở $\pm 1,5$.
- Trục dọc:** ô trái là MASE trung bình; ô phải là số chuỗi.
- Ký hiệu:** vạch đen ở ô phải là 0 (hoà).
- Nhìn vào đầu:** độ cao hai cột đầu ở ô trái; hai bên vạch 0 ở ô phải.
- Kết luận:** hai cột đầu gần bằng nhau và thấp hơn seasonal naive; ở ô phải, chuỗi chia gần đều hai bên: mỗi mô hình thắng ở khoảng một nửa.

Khi nào dùng, khi nào không. Chạy cả hai và chọn bằng backtest cho dữ liệu của bạn, hoặc lấy trung bình hai dự báo (buổi 24). SARIMA chậm và khó với chu kỳ dài (dữ liệu giờ có $m = 168$): dùng hồi quy Fourier (buổi 18).

Tóm lại. Trên 366 chuỗi du lịch, AutoARIMA và AutoETS cùng thắng seasonal naive có ý nghĩa, và hoà nhau. Quên khai chu kỳ mùa vụ làm AutoARIMA thua cả baseline.

Tự kiểm tra. Bạn chạy `AutoARIMA()` trên doanh số tuần có mùa vụ năm và thấy nó thua seasonal naive. Kiểm gì đầu tiên?

Đáp án (tự làm trước rồi mới đọc)

Tham số `season_length`: mặc định 1 là không có mùa vụ; dữ liệu tuần với mùa vụ năm cần 52. Rồi kiểm phần dư: ACF còn gai ở trễ 52 là dấu hiệu quên mùa vụ. Nhầm hay gặp: kết luận "ARIMA kém" mà không xem mô hình nó đã chọn.

5. Lab từng bước

Lệnh gõ trong terminal ở thư mục `lab/`. Code các bước nằm sẵn trong `code/lab.ipynb` (mở bằng `python lab.py notebook` hoặc VS Code), chạy từng ô từ trên xuống. Bạn sửa `code/arima.py`; notebook tự nạp lại bản mới.

Bước 1 — Mô phỏng và ACF/PACF

Mục đích: nối mục 4.1 với số, không cần sửa.

```
python lab.py up          # một lần: môi trường + dữ liệu G.17 và Tourism, kiểm sha256
python lab.py check       # 3/6 test đồ
python lab.py notebook    # chạy ô bước 1
```

Độc kết quả: bảng ACF/PACF của ba mô hình mô phỏng như hình mục 4.1. Đoán bậc từng mô hình trước khi nhìn tên.

Bước 2 — Sản lượng công nghiệp

Mục đích: đọc PACF, chọn bậc, so AICc với auto-ARIMA (mục 4.2). Ô in bảng ứng viên.

Độc kết quả: PACF như hình mục 4.2. Cột kiểm phần dư ghi "ổn" ở mọi dòng, kể cả ARIMA(1,1,0): đáng ngờ. Sửa `kiem_phan_du` để gọi `ljung_box` trên phần dư (bỏ $d + D \times m$ điểm đầu, bậc tự do trừ $p + q + P + Q_m$) và trả `dat` = $p \geq 0,05$ (mục 4.4). Chạy lại: bảng như mục 4.2.

Bước 3 — Chuỗi du lịch T33

Mục đích: nhận ra phần mùa vụ bị quên (mục 4.3).

Độc kết quả: mô hình mặc định là ARIMA(0,1,1), phần dư không đạt, ACF phần dư ở trễ 12 lớn. Sửa mặc định `seasonal_order` của `mo_hinh_tu_chon` thành `(0, 1, 1)`. Chạy lại: bảng như mục 4.3. Tiếp theo, auto-ARIMA vẫn chọn mô hình không mùa vụ: sửa `MUA_VU_ARIMA = 12`, chạy lại ô: auto → SARIMA(0,1,1)(0,1,2)12, cách mô hình tự chọn 0,9 đơn vị AICc.

Bước 4 — Khoảng dự báo

Mục đích: kiểm quy tắc $\sqrt{h}$ (mục 4.5), không cần sửa.

Độc kết quả: độ rộng khoảng 95% trên log nở đúng theo căn của tầm, như hình mục 4.5.

Bước 5 — 366 chuỗi

Mục đích: so với AutoETS và seasonal naive (mục 4.6). Lần chạy đầu mất khoảng 6 phút, kết quả được lưu vào `du-lieu/cache/` cho lần sau. Rồi:

```
python lab.py check      # 6/6 xanh
```

Độc kết quả: hai bảng như mục 4.6. Xanh 6/6 là xong; `test_auto_arima_co_mua_vu` còn đỏ thì `MUA_VU_ARIMA` vẫn là 1.

6. Lỗi thường gặp & cách chẩn đoán

Triệu chứng	Nguyên nhân	Chẩn đoán	Sửa
auto-ARIMA thua seasonal naive trên dữ liệu mùa vụ	quên <code>season_length</code>	in mô hình được chọn	khai chu kỳ đúng
Phần dư có gai ở trễ 12	thiếu phần mùa vụ	ACF phần dư	thêm $D = 1$ và MA mùa vụ
Mọi mô hình "phần dư ổn"	không thật sự kiểm	tính Ljung-Box tay một lần	Ljung-Box với đúng bậc tự do
AICc "tốt hơn nhiều" khi đổi d	so AICc giữa hai mức sai phân	xem d , D của hai mô hình	chọn d trước, chỉ so cùng d
Độc PACF ra AR bậc cao mà AICc vẫn kém	chuỗi thật là ARMA	cả ACF và PACF tắt dần	để auto-ARIMA dò ARMA
Hệ số AR gần 1, dự báo trôi	chuỗi chưa dừng, thiếu sai phân	KPSS	thêm $d = 1$
Khoảng dự báo nở rất nhanh	mô hình gần bước ngẫu nhiên	dạng mô hình	chấp nhận, hoặc mô hình có nhiều cấu trúc hơn
SARIMA chạy rất lâu	chu kỳ dài ($m = 168$)	độ dài chu kỳ	Fourier (buổi 18), MSTL

7. Bài tập về nhà

- Mô phỏng.** Mô phỏng AR(1) với $\phi = 0,95$ và $0,3$, mỗi cái 200 điểm. So ACF. Cái nào khó phân biệt với chuỗi không dừng?
- COVID.** Chạy auto-ARIMA trên sản lượng công nghiệp tới 12/2024. Mô hình và phần dư đối thể nào? Nhớ lại buổi 11.
- Log hay không.** Chạy SARIMA(0,1,1)(0,1,1)₁₂ trên T33 không lấy log. Phần dư có còn đạt không, vì sao?

8. Tiêu chí "Xong khi"

- [] `python lab.py check` xanh 6/6.
- [] Đoán đúng bậc ba mô hình mô phỏng từ ACF/PACF.
- [] Mô hình tự chọn cho T33 qua Ljung-Box và AICc cách auto-ARIMA không quá 2 đơn vị; giải thích từng hệ số.
- [] Tính tay Ljung-Box trên hai trễ và khoảng dự báo của bước ngẫu nhiên.
- [] So AutoARIMA, AutoETS, seasonal naive trên 366 chuỗi có DM, và nói kết luận.

9. Đọc thêm

- Hyndman, R.J. & Athanasopoulos, G. *FPP3*, chương 9: <https://otexts.com/fpp3/arima.html>
- Hyndman, R.J. & Khandakar, Y. (2008). Automatic time series forecasting: the forecast package for R. *Journal of Statistical Software* 27(3).
- Box, G.E.P., Jenkins, G.M., Reinsel, G.C. & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*, 5th ed. Wiley.

- Ljung, G.M. & Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika* 65(2).
- statsforecast: `ARIMA`, `AutoARIMA` — <https://nixtlaverse.nixtla.io/statsforecast/>